

KHOA TOÁN KINH TẾ



ĐỀ TÀI

**ỨNG DỤNG THỊ GIÁC MÁY TÍNH TRONG NHẬN DIỆN
RẪN ĐỘC: ĐÁNH GIÁ TỪ MACHINE LEARNING ĐẾN
DEEP LEARNING**

GVHD: TS. LÊ THANH HOA

NHÓM SINH VIÊN THỰC HIỆN:

Họ và tên	MSSV
Nguyễn Thúc Ái Ngân	K234131491
Vương Nguyễn Hồng Ngọc	K234131494
Nguyễn Thiên Quốc	K234131503
Trương Thị Trang Thi	K234131506
Lê Thị Phương Trinh	K234131517

MỤC LỤC

DANH MỤC HÌNH ẢNH	iii
CHƯƠNG 1. GIỚI THIỆU.....	1
1.1. Lý do chọn đề tài	1
1.2. Mục tiêu nghiên cứu	2
1.3. Đối tượng và phạm vi nghiên cứu	3
1.4. Đóng góp của đề tài	3
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	4
2.1. Khái quát về thị giác máy tính, mô hình học đa nhiệm và mô hình phân cấp.....	4
2.2 Một số loài rắn đặc trưng.....	5
2.2.1 Phân lớp không độc	5
2.2.2 Phân lớp độc	8
2.3. Lý thuyết mô hình MachineLearning - <i>XGBoost</i>	14
2.4. Lý thuyết mô hình Deep Learning - VIT.....	15
2.5. Cơ chế giải thích Attention Rollout cho mạng Transformer	16
2.6.Cơ sở y khoa về nọc độc và sơ cấp cứu.....	18
2.6.1. Cơ sở y khoa về nọc độc rắn.....	18
2.6.2. Cơ sở y khoa về sơ cấp cứu khi bị rắn cắn	19
CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU.....	21
3.1 Thu thập và tiền xử lý dữ liệu.....	21
3.1.1. Xây dựng và tổ chức bộ dữ liệu.....	21
3.1.2. Gán nhãn và mã hóa dữ liệu	22
3.1.3. Phân chia tập dữ liệu	23
3.1.4. Tiền xử lý và tăng cường dữ liệu ảnh	24
3.1.5. Cân bằng dữ liệu bằng Weighted Random Sampler.....	25
3.2. Khung nghiên cứu đề xuất.....	25
3.3. Mô hình cơ sở.....	26
3.4. Mô hình học phân cấp (Hướng 1).....	27
3.5. Mô hình học đa nhiệm (Hướng 2)	28
3.6. Mô hình kết hợp	29
CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU	30
4.1. Kết quả mô hình cơ sở.....	31
4.2. Kết quả mô hình phân tầng.....	32
4.3. So sánh kết quả phân tầng giữa mô hình cơ sở và mô hình phân cấp	35

4.4. Kết quả mô hình học đa nhiệm.....	36
4.5. Kết quả mô hình kết hợp	39
4.6. Trực quan hóa mô hình với Attention Rollout.....	41
CHƯƠNG 5. THẢO LUẬN VÀ HÀM Ý	43
5.1. Thảo luận kết quả	44
5.2. Hàm ý thực tiễn	44
5.3. Hạn chế của nghiên cứu.....	45
5.4. Hướng phát triển tương lai	45
TÀI LIỆU THAM KHẢO.....	47

DANH MỤC HÌNH ẢNH

Hình 2.2.1.1. Rắn đèn đuôi gai	5
Hình 2.2.1.2. Rắn giun thường	5
Hình 2.2.1.3a. Rắn đuôi đỏ	6
Hình 2.2.1.3b. Rắn bông súng	6
Hình 2.2.1.3c. Rắn bông súng	6
Hình 2.2.1.3d. Rắn dẻ	7
Hình 2.2.1.4. Rắn trun	7
Hình 2.2.2.1a. Rắn lục núi	8
Hình 2.2.2.1b. Rắn chàm quạp	8
Hình 2.2.2.1c. Rắn lục đuôi đỏ Cardamon	9
Hình 2.2.2.1d. Rắn lục cườm	9
Hình 2.2.2.2a. Rắn đèn mỡ	10
Hình 2.2.2.2b. Rắn đèn bụng vàng	10
Hình 2.2.2.3. Rắn đèn cạp nong môi vàng	11
Hình 2.2.2.4a. Rắn hổ mang chúa	11
Hình 2.2.2.4b. Rắn cạp nong	12
Hình 2.2.2.4c. Rắn cạp nia nam	12
Hình 2.2.2.4d. Rắn lá khô đốm	13
Hình 2.2.2.5. Rắn hoa cỏ he le	13
Hình 2.4a. Sơ đồ kiến trúc mô hình Vision Transformer (ViT) để phân loại các giai đoạn bệnh Alzheimer từ ảnh MRI não	15
Hình 2.4b. Sơ đồ cơ chế Scaled Dot-Product Attention và Multi-Head Attention trong kiến trúc Transformer	16
Hình 2.6.1. Mức độ nặng nhất của một vết thương khi bị rắn cắn - Hoại tử	19
Hình 3.1.1. Mô tả thống kê cho tập dữ liệu hình ảnh rắn	22
Hình 3.2. Sơ đồ quy trình hoạt động của hệ thống nhận dạng rắn của nghiên cứu	26
Hình 4.1a. Kết quả các chỉ số đánh giá hiệu suất mô hình phân loại rắn độc XGBoost	31
Hình 4.1b. Ma trận nhầm lẫn dự báo rắn độc - không độc của mô hình XGBoost	32
Hình 4.2a. Kết quả các chỉ số đánh giá hiệu suất cấp 1 mô hình phân cấp ViT hướng 1	33
Hình 4.2b. Kết quả chỉ số đánh giá hiệu suất Cấp 2 mô hình phân cấp ViT hướng 1 theo cơ chế chốt cứng và chốt mềm	34
Hình 4.2c. Ma trận nhầm lẫn dự báo Cấp 2 mô hình phân cấp ViT hướng 1 theo cơ chế chốt cứng và chốt mềm	34
Hình 4.4a. Kết quả các chỉ số đánh giá hiệu suất mô hình đa nhiệm ViT hướng 2 phân loại rắn độc - không độc tại ngưỡng 0.5	36
Hình 4.4b. Kết quả các chỉ số đánh giá hiệu suất mô hình đa nhiệm ViT hướng 2 phân loại rắn độc - không độc tại ngưỡng tối ưu 0.056	37
Hình 4.4c. Kết quả các chỉ số đánh giá hiệu suất mô hình đa nhiệm ViT hướng 2 phân loại theo họ rắn	38
Hình 4.4d. Ma trận nhầm lẫn mô hình đa nhiệm ViT hướng 2 phân loại rắn độc - không độc và theo họ rắn	39
Hình 4.5a. Kết quả các chỉ số đánh giá hiệu suất mô hình kết hợp phân loại rắn độc - không độc tại ngưỡng tối ưu 0.051	40

Hình 4.5b. Kết quả các chỉ số đánh giá hiệu suất mô hình kết hợp phân loại theo họ rắn.....	41
Hình 4.5c. Ma trận nhầm lẫn mô hình kết hợp phân loại rắn độc - không độc và phân loại theo họ rắn	41
Hình 4.6. Kết quả kiểm tra bằng Attention Rollout cho rắn nước (không độc) và rắn lục (có độc)	43

Ứng dụng thị giác máy tính trong nhận diện rắn độc: Từ đánh giá bằng Machine Learning đến Deep Learning

CHƯƠNG 1. GIỚI THIỆU

1.1. Lý do chọn đề tài

Rắn cắn là một trong những tai nạn y tế nguy hiểm và bị xem nhẹ nhất tại các quốc gia nhiệt đới đang phát triển. Theo Tổ chức Y tế Thế giới (WHO), mỗi năm có khoảng 5,4 triệu người bị rắn cắn trên toàn cầu, trong đó từ 1,8 đến 2,7 triệu ca dẫn đến nhiễm độc, số ca tử vong ước tính dao động từ 81.410 đến 137.880 người mỗi năm và khoảng 400.000 người phải chịu tàn tật vĩnh viễn như cắt cụt chi, mù lòa hoặc suy thận mãn tính. (Kasturiratne, et al., 2008) ước tính gánh nặng tối thiểu là 421.000 ca nhiễm độc và 20.000 ca tử vong mỗi năm, với phần lớn tập trung ở Nam Á, Đông Nam Á và châu Phi cận Sahara. (Longbottom, et al., 2018) xác định khoảng 92,66 triệu người đang sinh sống trong các vùng địa lý dễ bị tổn thương do rắn cắn, trong đó Đông Nam Á là một trong những điểm nóng toàn cầu. Trước bối cảnh đó, vào ngày 9 tháng 6 năm 2017, WHO chính thức bổ sung rắn cắn vào nhóm Bệnh nhiệt đới bị bỏ quên loại A và năm 2019 công bố Lộ trình chiến lược với mục tiêu giảm 50% tỷ lệ tử vong và tàn tật do rắn cắn vào năm 2030.

Tại Việt Nam, gánh nặng y tế do rắn cắn đặc biệt nghiêm trọng do mức độ tiếp xúc cao với môi trường tự nhiên và đặc điểm đa dạng sinh học. Với khoảng 246 loài rắn được ghi nhận, trong đó hơn 60 loài có độc tính nguy hiểm với người, qua đó đưa Việt Nam trở thành một trong những khu vực có mức độ đa dạng động vật lưỡng cư và bò sát cao trên thế giới. Ước tính mỗi năm cả nước xảy ra khoảng 30.000 ca rắn cắn, với tỷ lệ tử vong lên đến 80 người trên mỗi triệu dân mỗi năm. Nghiên cứu tại Cần Thơ của (Thang & al., 2020) cho thấy tỷ lệ mắc thực tế trong cộng đồng có thể lên đến 48 ca trên 100.000 người/năm, trong khi dữ liệu bệnh viện chỉ ghi nhận khoảng một phần ba số ca thực tế, phản ánh mức độ báo cáo thiếu và sự tiếp cận y tế còn hạn chế, đặc biệt ở vùng nông thôn và miền núi. Theo phân tích trên 5.805 ca tại Trung tâm Chống độc Bệnh viện Bạch Mai giai đoạn 2008 - 2020, Rắn hổ mang chiếm tỷ lệ cao nhất (39,69% số ca nhập viện), tiếp theo là cạp nia/cạp nong (10,08%) và rắn lục (8,39%).

Một thách thức then chốt trong điều trị rắn cắn là việc xác định chính xác loài rắn gây ra vết cắn, bởi mỗi nhóm rắn độc có cơ chế tác động của nọc độc và phác đồ điều trị hoàn toàn khác nhau: nọc độc thần kinh (neurotoxin) của họ Elapidae đòi hỏi ưu tiên hỗ trợ hô hấp và theo dõi liệt cơ, trong khi nọc gây hoại tử mô và rối loạn đông máu (hemotoxin/cytotoxin) của họ Viperidae yêu cầu phác đồ chống đông và sử dụng huyết thanh kháng nọc đặc hiệu. Bolon et al. (2020) ước tính rằng gần 50% số ca rắn cắn trên toàn cầu không xác định được loài rắn. Thực trạng này đặc biệt rõ nét tại các cơ sở y tế tuyến dưới, trước năm 2021, nhân viên Trung tâm Chống độc Bệnh viện Bạch Mai, do thiếu sự chuẩn hóa phân loại và hợp tác với chuyên gia về loài Bò sát, chỉ có thể phân chia rắn độc thành bốn nhóm thô: hổ mang, cạp, lục và nhóm khác, không đủ để phân biệt nhiều loài có hình thái tương tự nhưng phác đồ điều trị khác nhau.

Trong bối cảnh đó, các phương pháp học máy và thị giác máy tính đã mở ra hướng tiếp cận mới đầy tiềm năng. Nghiên cứu của Durso và cộng sự (2021) đã đặt nền tảng cho lĩnh vực nhận dạng rắn từ hình ảnh bằng cách xây dựng bộ dữ liệu chuẩn, định nghĩa bài toán và đề xuất hệ thống tiêu chí đánh giá thống nhất, tạo điều kiện cho việc so sánh khách quan giữa các mô

hình học có giám sát. Song song đó, chuỗi cuộc thi SnakeCLEF (Picek et al., 2020, 2021, 2022, 2023) đã thúc đẩy mạnh mẽ sự phát triển của các phương pháp học sâu quy mô lớn, mở rộng phạm vi nghiên cứu trên nhiều loài rắn và nhiều khu vực địa lý khác nhau. Đặc biệt, Bolon et al. (2022) đã xây dựng mô hình Vision Transformer (ViT) được huấn luyện trên 386.006 ảnh của 772 loài rắn từ 188 quốc gia, đạt Macro-F1 92,2% ở cấp độ loài, chứng minh rằng học sâu có thể đạt độ chính xác cao cho bài toán nhận diện rắn ở quy mô toàn cầu. Tuy nhiên, các mô hình được phát triển trên quy mô toàn cầu vẫn tồn tại những hạn chế khi áp dụng vào bối cảnh Việt Nam. Cụ thể, các bộ dữ liệu hiện có chưa phản ánh đầy đủ tính đa dạng của hơn 60 loài rắn độc ghi nhận tại Việt Nam, dẫn đến khả năng nhận dạng chưa tối ưu đối với các loài đặc hữu hoặc ít xuất hiện trong các tập dữ liệu quốc tế. Bên cạnh đó, các hệ thống này thường chỉ tập trung vào nhiệm vụ phân loại loài mà chưa tích hợp thông tin sơ cứu và hỗ trợ y tế phù hợp với các phác đồ điều trị tại địa phương. Ngoài ra, bài toán mất cân bằng dữ liệu nghiêm trọng giữa các loài phổ biến và các loài hiếm gặp trong nước vẫn chưa được giải quyết hiệu quả, gây ảnh hưởng đáng kể đến độ tin cậy của mô hình trong các tình huống thực tế.

Để giải quyết khoảng trống này, đề án xây dựng hệ thống nhận diện rắn độc áp dụng cho khoảng 85 loài tại Việt Nam. Hệ thống được xây dựng theo kiến trúc phân loại sử dụng Vision Transformer (ViT) làm mô hình nền tảng. Thay vì giới hạn ở một hướng tiếp cận đơn lẻ, nghiên cứu tiến hành đánh giá toàn đồng loạt các phương pháp phân loại khác nhau và đề xuất hai giải pháp cốt lõi mang tính ứng dụng cao nhất, Mô hình học đa nhiệm và mô hình kết hợp giữa hệ thống phân cấp và đa nhiệm. Trong khi mô hình đa nhiệm khai thác hiệu quả mối quan hệ tiềm ẩn giữa việc định danh họ loài và dự đoán tính độc, thì mô hình kết hợp lại tối ưu hóa luồng phân loại thông qua chiến lược đặt ngưỡng nhạy cảm. Cuối cùng, để tăng tính giải thích của hệ thống, kỹ thuật Attention Rollout được áp dụng để trực quan hóa các vùng ảnh mà Vision Transformer tập trung khi đưa ra quyết định phân loại. Đây là hệ thống kết hợp đồng thời phát hiện đối tượng, phân loại đa nhiệm và tích hợp tri thức lâm sàng sơ cứu cho rắn độc Việt Nam.

1.2. Mục tiêu nghiên cứu

Mục tiêu tổng quát:

Xây dựng hệ thống nhận diện và phân loại rắn từ ảnh chụp dựa trên kiến trúc Vision Transformer, hỗ trợ xác định mức độ nguy hiểm và nhận dạng nhóm loài rắn một cách tự động.

Mục tiêu cụ thể:

1. Xây dựng và tiền xử lý tập dữ liệu ảnh rắn với hệ thống nhãn, bao gồm nhãn mức độ độc (Có độc/Không độc) và nhãn nhóm họ, đồng thời áp dụng các kỹ thuật tăng cường dữ liệu nhằm nâng cao khả năng tổng quát hóa của mô hình.
2. Phát triển mô hình nhận dạng rắn dựa trên kiến trúc Vision Transformer (ViT) theo hướng học đa nhiệm và theo hướng kết hợp.
3. Huấn luyện mô hình để thực hiện hai nhiệm vụ: phân loại nhị phân Có độc/Không độc và phân loại đa lớp loài hoặc nhóm loài rắn, từ đó tận dụng mối quan hệ giữa các nhiệm vụ nhằm cải thiện hiệu suất nhận dạng tổng thể.
4. Đánh giá hiệu quả của hệ thống thông qua các chỉ số như Accuracy, Precision, Recall và F1-Score trên tập dữ liệu kiểm thử.

5. Áp dụng kỹ thuật Attention Rollout để trực quan hóa các vùng ảnh quan trọng mà mô hình Vision Transformer sử dụng trong quá trình đưa ra quyết định, góp phần tăng tính giải thích của hệ thống.
6. Xây dựng giao diện thử nghiệm cho phép người dùng tải ảnh lên, thực hiện nhận dạng và hiển thị kết quả dự đoán cùng bản đồ trực quan Attention Rollout.
7. Xây dựng giao diện thử nghiệm cho phép người dùng tải ảnh lên, thực hiện nhận dạng và hiển thị kết quả dự đoán cùng bản đồ trực quan Attention Rollout.

1.3. Đối tượng và phạm vi nghiên cứu

Đề tài tập trung nghiên cứu việc ứng dụng các phương pháp học sâu trong bài toán nhận dạng rắn từ ảnh, với trọng tâm là kiến trúc Vision Transformer (ViT), các phương pháp tiếp cận học đa nhiệm và học kết hợp. Bên cạnh đó, đề tài cũng xem xét các phương pháp giải thích mô hình, cụ thể là kỹ thuật Attention Rollout, nhằm hỗ trợ phân tích và trực quan hóa quá trình đưa ra dự đoán của mô hình. Dữ liệu nghiên cứu là tập ảnh các loài rắn được gán nhãn cho hai nhiệm vụ gồm xác định mức độ độc (Có độc hoặc Không độc) và nhận dạng họ loài tương ứng. Tiếp hợp thêm hệ thống quy trình sơ cấp cứu lâm sàng đối với các vết cắn do rắn độc gây ra.

Trong phạm vi nghiên cứu, đề tài sử dụng các ảnh tĩnh được thu thập từ những nguồn dữ liệu mở và được xử lý, gán nhãn phục vụ cho bài toán học đa nhiệm. Mỗi ảnh đồng thời chứa thông tin về mức độ độc và thông tin loài, cho phép mô hình học và dự đoán cả hai nhiệm vụ trên cùng một đầu vào. Nghiên cứu không xem xét dữ liệu video, âm thanh hoặc các nguồn dữ liệu cảm biến khác. Hệ thống được xây dựng trên nền tảng Vision Transformer, trong đó các nhiệm vụ phân loại mức độ độc và nhận dạng loài cùng khai thác tập đặc trưng. Ngoài ra, kỹ thuật Attention Rollout được sử dụng để trực quan hóa các vùng ảnh quan trọng, qua đó hỗ trợ giải thích kết quả dự đoán của mô hình. Đề tài được triển khai trên các hệ thống ứng dụng thực tế dựa trên kết quả của các mô hình.

1.4. Đóng góp của đề tài

Đề tài xây dựng một hệ thống nhận diện rắn từ ảnh dựa trên kiến trúc Vision Transformer kết hợp phương pháp học đa nhiệm và phương pháp kết hợp. Mô hình được thiết kế để thực hiện hai nhiệm vụ gồm phân loại mức độ độc (Có độc/Không độc) và nhận dạng họ rắn từ cùng một ảnh đầu vào. Việc áp dụng nhiều phương pháp, giúp khai thác hiệu quả mối liên hệ giữa các đặc trưng sinh học của rắn, từ đó nâng cao khả năng nhận dạng và cải thiện hiệu suất tổng thể của hệ thống. Việc áp dụng kỹ thuật Attention Rollout nhằm trực quan hóa các vùng ảnh mà mô hình tập trung khi đưa ra dự đoán. Điều này giúp tăng tính minh bạch của hệ thống, hỗ trợ quá trình đánh giá và kiểm chứng kết quả nhận dạng, đồng thời góp phần nâng cao mức độ tin cậy khi triển khai các mô hình học sâu trong thực tế.

Bên cạnh đó, đề tài xây dựng và chuẩn hóa tập dữ liệu hình ảnh rắn với hệ thống nhãn phục vụ cho bài toán học đa nhiệm, bao gồm nhãn mức độ độc và nhãn họ loài tương ứng. Tập dữ liệu này không chỉ phục vụ quá trình huấn luyện và đánh giá mô hình trong nghiên cứu mà còn có thể được sử dụng làm nguồn dữ liệu tham khảo cho các nghiên cứu tiếp theo trong lĩnh vực thị giác máy tính và nhận dạng động vật hoang dã. Ngoài ra, dữ liệu cũng có tiềm năng được mở rộng và ứng dụng trong các bài toán như phân loại ảnh, phát hiện đối tượng hoặc các mô hình học đa nhiệm khác trong tương lai.

Xét trên khía cạnh ứng dụng, hệ thống có tiềm năng trở thành công cụ hỗ trợ nhận diện nhanh các loài rắn thông qua ảnh chụp từ điện thoại hoặc máy ảnh thông thường. Trong điều kiện thực tế, đặc biệt tại các khu vực nông thôn, miền núi hoặc vùng có nhiều động vật hoang dã, người dân thường gặp khó khăn trong việc phân biệt các loài rắn do thiếu kiến thức chuyên môn. Một hệ thống nhận dạng tự động có thể hỗ trợ cung cấp thông tin ban đầu về loài rắn xuất hiện, từ đó giúp nâng cao nhận thức và giảm các hành vi xử lý thiếu an toàn.

Ngoài ra, kết quả nghiên cứu còn có thể được ứng dụng trong các hoạt động giáo dục, bảo tồn đa dạng sinh học và nghiên cứu động vật học. Hệ thống có thể hỗ trợ sinh viên, nhà nghiên cứu hoặc những người yêu thích thiên nhiên trong việc tìm hiểu và nhận diện các loài rắn tại Việt Nam một cách thuận tiện hơn. Đây cũng là nền tảng để phát triển các ứng dụng nhận dạng sinh vật tự động trên thiết bị di động hoặc các hệ thống hỗ trợ thực địa trong tương lai.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Khái quát về thị giác máy tính, mô hình học đa nhiệm và mô hình phân cấp

Thị giác máy tính (Computer Vision) là một lĩnh vực của trí tuệ nhân tạo tập trung vào việc giúp máy tính thu nhận, xử lý và hiểu thông tin từ hình ảnh hoặc video. Khác với các phương pháp xử lý ảnh truyền thống chủ yếu dựa trên các phép biến đổi, lọc nhiễu hoặc trích xuất đặc trưng thủ công, các mô hình thị giác máy tính hiện đại có khả năng tự động học đặc trưng từ dữ liệu thông qua quá trình huấn luyện. Sự thành công của mạng nơ-ron sâu, đặc biệt từ nghiên cứu AlexNet của Krizhevsky, Sutskever và Hinton (2012), đã tạo ra bước ngoặt quan trọng khi cho phép mô hình học được các biểu diễn đặc trưng phân cấp từ dữ liệu ảnh với độ chính xác vượt trội so với các phương pháp truyền thống. Ngày nay, thị giác máy tính được ứng dụng rộng rãi trong các bài toán phân loại ảnh, phát hiện đối tượng, phân đoạn ảnh và nhận dạng sinh vật trong tự nhiên.

Học đa nhiệm (Multi-task Learning) là phương pháp huấn luyện một mô hình để thực hiện đồng thời nhiều nhiệm vụ có liên quan trên cùng một không gian đặc trưng chung. Theo Caruana (1997), việc chia sẻ tri thức giữa các nhiệm vụ giúp mô hình học được những biểu diễn tổng quát hơn, từ đó cải thiện khả năng khái quát hóa và giảm hiện tượng quá khớp. Trong các mô hình học sâu hiện đại, học đa nhiệm thường được xây dựng với một backbone dùng chung kết hợp nhiều nhánh đầu ra cho từng nhiệm vụ riêng biệt. Ưu điểm của phương pháp này là tận dụng được mối quan hệ giữa các nhiệm vụ để nâng cao hiệu suất tổng thể và tiết kiệm tài nguyên tính toán. Tuy nhiên, nếu các nhiệm vụ có mức độ liên quan thấp hoặc mục tiêu tối ưu khác biệt đáng kể, hiện tượng xung đột giữa các nhiệm vụ (task conflict) có thể làm suy giảm hiệu năng của mô hình.

Bên cạnh học đa nhiệm, phân loại phân cấp (Hierarchical Classification) là một hướng tiếp cận phổ biến đối với các bài toán có cấu trúc nhãn nhiều cấp. Trong phương pháp này, quá trình phân loại được thực hiện từ mức tổng quát đến mức chi tiết, chẳng hạn như phân loại độc tính trước khi xác định họ hoặc loài. Theo Silla và Freitas (2011), việc khai thác cấu trúc phân cấp giúp giảm không gian tìm kiếm và tận dụng được mối quan hệ ngữ nghĩa giữa các lớp dữ liệu. Tuy nhiên, nhược điểm lớn nhất của phương pháp này là hiện tượng lan truyền sai số (error propagation), khi một quyết định sai ở cấp trên có thể ảnh hưởng trực tiếp đến toàn bộ quá trình

phân loại ở các cấp phía dưới. Do đó, việc lựa chọn giữa mô hình phân cấp và học đa nhiệm phụ thuộc vào đặc điểm bài toán cũng như yêu cầu về độ chính xác và độ tin cậy của hệ thống.

2.2 Một số loài rắn đặc trưng

2.2.1 Phân lớp không độc

2.2.1.1 Rắn biển Hydrophiidae

* Rắn đèn đuôi gai (*Aipysurus eydouxii*)



Hình 2.2.1.1. Rắn đèn đuôi gai

Cơ thể có dạng hình trụ tròn, không bị dẹp hai bên. Hệ thống vảy trên thân xếp chồng lên nhau, trong đó, phần vảy bụng phát triển lớn với chiều ngang chiếm khoảng 1/3 đến 1/2 chiều rộng thân. Phân bố ở vùng nước ven bờ và cửa sông có dòng chảy mạnh, thức ăn chủ yếu là trứng cá. Chúng sống đơn độc và chỉ ghép đôi vào mùa sinh sản. Mặc dù thuộc nhóm rắn biển có nọc độc thần kinh nguy hiểm, sự thích nghi với chế độ ăn chuyên biệt đã khiến răng nanh và tuyến nọc độc của chúng tiêu giảm gần như hoàn toàn.

2.2.1.2 Rắn giun Typhlopidae

* Rắn giun thường (*Indotyphlops braminus*)



Hình 2.2.1.2. Rắn giun thường

Kích thước nhỏ, thân hình trụ mảnh dài khoảng 95-200 mm. Đầu ngắn, mõm tròn, mắt rất nhỏ và lưỡi màu trắng. Thân phủ 20 hàng vảy dọc không giảm hàng, màu lưng đen, nâu hoặc nâu đỏ, nhạt dần về phía bụng, mới nở có màu đen đồng nhất. Sống chui rúc dưới đất, trong gỗ mục hoặc các đồng cỏ nát ở khu dân cư và rừng thường xanh, phân bố từ mực nước biển đến độ cao 1.640 m. Chúng hoạt động mạnh vào mùa mưa, trú ẩn sâu dưới đất vào mùa đông và mùa hè, đồng thời rất kém chịu nhiệt. Thức ăn chủ yếu là mối và trứng kiến. Đặc biệt, loài này sinh sản đơn tính, con cái đẻ từ 1-7 trứng và các cá thể con đều là giống cái, hiện chưa ghi nhận cá thể đực trong tự nhiên.

2.2.1.3 Rắn nước Colubridae

* Rắn đuôi đỏ (*Gonyosoma oxycephalum*)



Hình 2.2.1.3a. Rắn đuôi đỏ

Kích thước lớn, dài từ 80-240 cm, thân thon, đầu dài phân biệt rõ với cổ, mắt lớn và lưỡi màu xanh đen. Màu sắc cơ thể đa dạng với các gam xanh lục, vàng hoặc nâu đất; đuôi dài, màu nâu đậm đến nâu đen. Thân có 19-23 hàng vảy giữa thân, 186-257 vảy bụng và 91-149 cặp vảy dưới đuôi. Chủ yếu sống trong rừng thường xanh ở độ cao 400-1.650 m, có tập tính sống trên cây hoặc xen kẽ giữa cây và mặt đất. Chúng hoạt động kiếm ăn về đêm, thức ăn chủ yếu là các loài lưỡng cư và bò sát nhỏ, ban ngày thường nghỉ trên cây và đôi khi xuống các khe suối hoặc khu vực nương rẫy để tìm mồi.

* Rắn bông súng (*Enhydris enhydris*)



Hình 2.2.1.3b. Rắn bông súng

Kích thước nhỏ, đầu hơi dẹt phân biệt rõ với cổ, mắt nhỏ có đồng tử tròn và lỗ mũi nằm trên đỉnh đầu thích nghi với đời sống thủy sinh. Thân có 27-21-19 hàng vảy, 150-177 vảy bụng và vảy dưới đuôi kép. Mặt lưng màu nâu xám với hai sọc dọc thân đặc trưng, bụng có một sọc đen chạy dọc từ đầu đến lỗ huyết. Con cái thường có kích thước lớn hơn con đực, trong khi con đực có đuôi và đầu dài hơn, cơ quan sinh sản phát triển lệch về phía phải. Sống ở ao hồ, đầm lầy và vùng đất ngập nước ngọt, hoạt động chủ yếu vào ban ngày và thức ăn chính là cá. Đây là loài nở thai sinh (để con), mỗi lứa sinh từ 4-18 con non dài khoảng 14 cm và có màu sắc tương tự cá thể trưởng thành.

* Rắn cườm (*Chrysopelea ornata*)



Hình 2.2.1.3c. Rắn bông súng

Kích thước nhỏ, dài khoảng 130 cm, nổi bật với màu sắc sặc sỡ. Cơ thể màu vàng hoặc vàng xanh nhạt, các vảy viền đen tạo thành các vằn ngang và có chuỗi đốm đỏ hoặc cam dọc sống lưng. Đầu màu xanh lục có vết đen hoặc đen sọc vàng, bụng vàng xanh. Thân có 17-17-15 hàng vảy lưng, 207-253 vảy bụng và 110-138 vảy dưới đuôi phân đôi. Hoạt động ban ngày, phân bố chủ yếu ở đồng bằng và đồi thấp dưới 550 m. Thức ăn gồm thằn lằn, động vật gặm nhấm nhỏ và các loài rắn nhỏ khác. Đây là loài đẻ trứng, mỗi

lửa từ 6-12 trứng, rắn con dài 15-20 cm và có màu sắc tươi sáng hơn cá thể trưởng thành.

** Rắn dẻ (Lycodon davisonii)*




Hình 2.2.1.3d. Rắn dẻ

Kích thước nhỏ, đầu phân biệt rõ với cổ. Thân có 13-13 hàng vảy lưng nhẵn, 239 vảy bụng, vảy huyết đơn và 109 vảy dưới đuôi phân đôi. Màu lưng đen với 45 khoang trắng trên thân và 26 khoang trắng trên đuôi; đầu màu nâu đậm với một vệt kem nhạt kéo dài từ vùng cằm đến phía trên mắt, bụng chuyển từ màu kem sang xám về phía sau. Sống trên cây, thường trú ẩn trong các hốc cây lớn nhưng đôi khi xuất hiện trên mặt đất ở rừng thường xanh thứ sinh khoảng 350 m. Thức ăn chủ yếu là nòng nọc và các loài ếch cây non.

2.2.1.4. Rắn trun Cyliodrophidae

** Rắn trun Jody (Cylindrophis jodiae)*



Hình 2.2.1.4. Rắn trun

Đây là loài rắn cỡ trung bình (thân dài 297-328 mm) mang đặc trưng phần đầu đẹp, thon liền khối với cổ. Chúng có hệ thống 19-23 hàng vảy thân nhẵn, 182-192 vảy bụng, lỗ mũi tròn nằm trên vảy mũi nguyên và đặc biệt khuyết thiếu các vảy gian mũi, vảy má hay trước mắt. Nổi bật với tông nền xám đen bao phủ cơ thể, điểm tuyết 27-51 sọc ngang mảnh màu vàng nhạt trên lưng và 40-51 sọc lớn hơn chạy từ sườn xuống bụng (thường xếp so le hoặc nối liền), trong khi vùng đầu sẫm màu có lẫn các vệt vàng ở mép và hống. Loài rắn này chuyên hoạt động vào ban ngày tại các sinh cảnh ngập nước hoặc ẩm ướt như đầm lầy, bãi lau sậy, bờ sông suối và khu nông nghiệp. Khẩu phần ăn chủ yếu của chúng là các động vật nhỏ tại nơi sinh sống (lươn, cá, ếch nhái), đi kèm với tập tính sinh sản bằng cách đẻ trứng diễn ra vào mùa mưa hàng năm.

2.2.2 Phân lớp độc

2.2.2.1 Rắn lục Viperidae

* Rắn lục núi (*Ovophis monticola*)



Hình 2.2.2.1a. Rắn lục núi

Kích thước trung bình, thân ngắn và chắc, đầu hình tam giác, mắt nhỏ, mõm ngắn. Thân có 25-23-17 hàng vảy có gờ mảnh, tám hậu môn nguyên, vảy dưới đuôi kép. Mặt lưng màu nâu nhạt đến nâu sẫm với các đốm lớn màu sẫm không đều, hai bên thân có nhiều đốm nhỏ, bụng màu trắng hoặc vàng. Chiều dài thường trên 500 mm, hoa văn lưng khác với rắn chàm quạp và rắn lục cườm. Ăn chủ yếu các loài thú nhỏ như chuột, ngoài ra còn ăn chim, thằn lằn và lưỡng cư. Mỗi lứa đẻ 5-10 trứng trong hốc đất hoặc nơi nhiều xác thực vật, rắn mẹ thường bảo vệ ổ trứng; rắn con mới nở dài 160-180 mm. Loài này sống ở các khu rừng núi cao đến 1.500 m, đôi khi gặp gần khu dân cư, và chủ yếu hoạt động, kiếm ăn vào ban đêm

* Rắn chàm quạp (*Calloselasma rhodostoma*)



Hình 2.2.2.1b. Rắn chàm quạp

Kích thước lớn, dài tới 1,8 m, thân chắc, đuôi ngắn. Đầu màu nâu sẫm với các sọc trắng kéo dài từ mõm đến cổ, mắt nhỏ có đồng tử hình bầu dục dựng đứng. Mặt lưng màu nâu nhạt đến nâu đỏ, có hai hàng đốm hình tam giác màu nâu sẫm viền đen và một sọc dọc sống lưng mảnh, giúp phân biệt với rắn lục núi và rắn lục cườm. Bụng màu vàng nhạt, đôi khi có các đốm nâu xám rải rác. Hoạt động chủ yếu vào ban đêm, ưa nơi ẩm và săn mồi theo kiểu phục kích, thức ăn gồm lưỡng cư, chuột, chim nhỏ và cả các loài rắn khác. Con cái đẻ 13-30 trứng và bảo vệ ổ đến khi nở; rắn con dài khoảng 155-175 mm. Chúng phân bố chủ yếu ở rừng đất thấp

nhưng có thể gặp ở độ cao tới 2.000 m. Nọc độc thuộc dạng độc tế bào, gây rối loạn đông máu, tổn thương mô và có thể đe dọa tính mạng con người.

* *Rắn lục đuôi đỏ cardamon* (*Trimeresurus cardamomensis*)



Hình 2.2.2.1c. Rắn lục đuôi đỏ Cardamon

Thân hình trụ, đầu hình tam giác tách biệt với cổ, mắt có đồng tử hình bầu dục dựng đứng và hốc má phát triển. Thân có 21 hàng vảy với gờ yếu, màu xanh lục; bụng xanh nhạt hơn. Con đực có sọc trắng dọc hai bên thân kéo dài lên sau mắt, con cái thường có các đốm xanh lam ở phần trước thân. Đuôi màu đỏ gạch đặc trưng, mắt màu vàng, giúp phân biệt với các loài rắn lục khác. Hoạt động về đêm, sống chủ yếu trong các khu rừng thường xanh còn nguyên vẹn và thường xuất hiện quanh các vũng nước để săn lưỡng cư. Chúng phổ biến hơn vào mùa mưa, rất hiếm gặp trong mùa khô và thường sống cùng sinh cảnh với rắn lục đuôi đỏ. Đây là loài rắn độc nguy hiểm, nọc độc có tác dụng gây hoại tử tế bào và có thể đe dọa tính mạng con người.

* *Rắn lục cườm* (*Protobothrops mucrosquamatus*)



Hình 2.2.2.1d. Rắn lục cườm

Mồm ngắn, đầu phủ các vảy nhỏ xếp khít, thân mang 25-25-19 hàng vảy có gờ rõ. Toàn thân màu nâu nhạt, đầu màu nâu sẫm, từ sau mắt đến góc hàm có một dải trắng nổi bật nằm trên một dải đen hẹp. Trên lưng có các đốm nâu đen phân bố dọc hai bên sống lưng, giúp phân biệt với rắn chàm quạp và rắn lục núi. Sống ở rừng thứ sinh và ven suối, từ vùng thấp đến độ cao khoảng 1.000 m. Chúng hoạt động chủ yếu vào ban đêm, ban ngày ẩn nấp trong hang hốc hoặc

dưới lớp thảm mục. Thức ăn gồm các loài thú nhỏ và lưỡng cư. Đây là loài rắn độc có nọc độc gây hoại tử tế bào, có thể đe dọa tính mạng con người.

2.2.2.2 Rắn biển Hydrophiidae

* Rắn đèn mỡ (*Hydrophis schistosus*)



Hình 2.2.2.2a. Rắn đèn mỡ

Thân hình trụ, phần sau dẹp bên thích nghi với môi trường nước, chiều dài trung bình khoảng 1,2 m, có thể đạt 1,4 m. Mặt lưng màu xanh xám với nhiều khoang xám đậm bao quanh thân, bụng màu trắng; mắt tương đối lớn và thân có 48 hàng vảy quanh cổ. Ăn chủ yếu cá và tôm, mùa sinh sản kéo dài từ tháng 3-9, mỗi lứa sinh 4-9 con. Chúng thường sống ở vùng biển ven bờ, cửa sông và nơi có nền đáy bùn cát, đôi khi có thể bò lên cạn. Đây là một trong những loài hiếm nhất thuộc họ Rắn biển.

* Rắn đèn bụng vàng (*Hydrophis caeruleus*)



Hình 2.2.2.2b. Rắn đèn bụng vàng

Kích thước nhỏ, thân và đuôi dẹp thích nghi với đời sống dưới nước. Cơ thể thường có màu vàng xen đen nổi bật, đôi khi màu nâu, với hoa văn biến đổi đa dạng và dễ nhầm với rắn biển *Hydrophis ornatus*. Ăn chủ yếu các loài cá sống thành đàn gần mặt nước. Mùa sinh sản vào mùa xuân, mỗi lứa đẻ 2-6 con. Chúng thường xuất hiện quanh các đám rác trôi nổi trên biển và đôi khi gặp ở vùng ven bờ. Đây là loài rắn biển có nọc độc rất mạnh, có khả năng gây tử vong.

2.2.2.3 Rắn hổ biển Laticaudinae

* Rắn đên cạp nong môi vàng (*Laticauda colubrina*)



Hình 2.2.2.3. Rắn đên cạp nong môi vàng

Thân hình trụ với đuôi dẹt như mái chèo, con cái có thể dài tới 1,42 m. Đầu màu đen, mõm và môi trên màu vàng đặc trưng, có dải vàng kéo dài từ mắt ra sau đầu. Lưng màu xám xanh với các khoang đen bao quanh thân, bụng màu vàng nhạt; các khoang thường thu hẹp hoặc đứt quãng ở mặt bụng. Có lối sống bán thủy sinh, vừa hoạt động dưới nước vừa lên bờ nghỉ ngơi và sinh sản. Thức ăn chủ yếu là các loài lươn, đôi khi ăn cá nhỏ. Mùa đẻ kéo dài từ tháng 9-12, mỗi ổ khoảng 10 trứng. Đây là loài rắn biển có nọc độc thần kinh rất mạnh, có khả năng gây tử vong.

2.2.2.4 Rắn hổ Elapidae

* Rắn hổ mang chúa (*Ophiophagus hannah*)



Hình 2.2.2.4a. Rắn hổ mang chúa

Thường dài 3-4 m, có thể vượt quá 5 m. Thân thon dài, đầu lớn tách biệt với cổ; khi bị đe dọa có thể bạnh cổ nhưng hẹp hơn rắn hổ mang thường. Cá thể trưởng thành có màu vàng lục, nâu ô liu đến xám đen, bụng nhạt màu hơn, cá thể non màu đen với nhiều khoang ngang vàng nhạt hoặc trắng kem và có hoa văn chữ V ngược ở cổ, là đặc điểm nhận dạng đặc trưng. Sống chủ yếu ở rừng tự nhiên, rừng tre nứa và ven suối vùng trung du, miền núi. Chúng leo cây và bơi giỏi, hoạt động cả ngày lẫn đêm, thức ăn chủ yếu là các loài rắn khác. Mùa sinh sản từ tháng 4-5, con cái làm tổ bằng lá khô, đẻ 20-30 trứng và bảo vệ tổ cho đến khi trứng nở.

Rắn con dài khoảng 40-50 cm và đã mang nọc độc mạnh. Đây là loài rắn có nọc độc thần kinh rất mạnh, có thể gây tử vong nếu không được điều trị kịp thời.

* *Rắn cạp nong* (*Bungarus fasciatus*)



Hình 2.2.2.4b. Rắn cạp nong

Rắn độc cỡ tương đối lớn, thường dài trên 1m. Đầu lớn và ngắn, ít phân biệt với cổ, mắt tương đối nhỏ và tròn, thân thường nặng nề, đuôi ngắn, mút đuôi tròn, giữa sống lưng có một gờ dọc rất rõ. Hàng vảy sống lưng hình sáu cạnh, lớn hơn vảy bên. Thân có khoanh đen và khoanh vàng xen kẽ, các khoanh xấp xỉ bằng nhau. Là rắn độc phổ biến khắp nơi, một trong những loài rắn độc phổ biến nhất ở đồng bằng, trung du và miền núi. Sống trong rừng hoặc những nơi gần chỗ ở của con người, thường gặp chúng nhiều hơn cả ở những địa hình cao giáp với nước, sống trong hang chuột hay hang mối đã bỏ ở bờ ruộng, gò đồng, bờ sông, bờ đê, vườn tược, bụi tre, bờ ao.

* *Rắn cạp nia nam* (*Bungarus candidus*)



Hình 2.2.2.4c. Rắn cạp nia nam

Thân thon với vảy nhẵn bóng và hàng vảy sống lưng giữa phình rộng đặc trưng. Toàn thân màu đen bóng xen kẽ 18-26 khoang trắng rõ rệt, bụng màu trắng ngà, vùng thái dương và hai bên cổ có màu trắng nổi bật. Đầu nhỏ, ít phân biệt với cổ, mắt nhỏ có đồng tử tròn. Loài này dễ nhầm với rắn cạp nia bắc nhưng có số khoang trắng trên thân ít hơn và không có dấu chữ V nhạt trên đỉnh đầu. Hoạt động chủ yếu vào ban đêm, sống ở rừng nhiệt đới, bụi rậm và nương rẫy ở độ cao khoảng 300-1.500 m. Ban ngày chúng ẩn dưới hốc đất, lá mục hoặc khe đá. Thức ăn chủ yếu là các loài rắn khác, ngoài ra còn ăn thằn lằn và lưỡng cư. Đây là loài có nọc độc thần kinh cực mạnh, có thể gây liệt hô hấp và tử vong nếu không được điều trị kịp thời.

* *Rắn lá khô đốm (Calliophis maculiceps)*




Hình 2.2.2.4d. Rắn lá khô đốm

Dài khoảng 47 cm. Đầu màu nâu đen hoặc nâu sẫm, phân biệt rõ với thân màu cam đỏ đến nâu đỏ. Hoa văn trên thân biến đổi đa dạng, có thể có các đốm lớn, sọc đen dọc thân hoặc gần như không có hoa văn, phần cuối thân và chóp đuôi thường có khoang đen đặc trưng. Bụng màu hồng nhạt, mặt dưới đuôi có các khoang đen trắng không đối xứng. Hoạt động chủ yếu vào ban đêm, sống trong rừng rậm, nơi nhiều thảm mục, gỗ mục hoặc đá vụn ở độ cao đến khoảng 1.000 m. Thức ăn chủ yếu là các loài rắn nhỏ, đặc biệt là rắn giun, ngoài ra còn ăn thằn lằn. Con cái đẻ khoảng 2 trứng mỗi năm. Khi bị đe dọa, chúng cuộn tròn cơ thể, phô phần bụng đen trắng để cảnh báo, có thể giả chết và tiết mùi hôi để tự vệ. Đây là loài có nọc độc và cần thận trọng khi gặp trong tự nhiên.

2.2.2.5 Rắn nước Colubridae

* *Rắn hoa cỏ he le (Rhabdophis helleri)*



Hình 2.2.2.5. Rắn hoa cỏ he le

Dài khoảng 1-1,3 m, thân thon, đầu hơi dẹt và tách biệt với cổ. Thân màu xanh đen đến xám đen, nửa trước có các vệt đen không đều xen vùng sáng, mép vảy lưng nhạt màu. Cá thể non có các mảng vàng cam hoặc đỏ cam nổi bật ở vùng cổ, khi trưởng thành màu nhạt dần nhưng vẫn còn thấy ở hai bên gáy. Loài này khá giống rắn hoa cỏ Xiêm nhưng khác ở màu sắc vùng cổ và phạm vi phân bố. Hoạt động chủ yếu vào ban ngày, thường gặp ở ruộng nước, bờ suối, đầm lầy, rừng thứ sinh và vùng nhiều bụi rậm, từ đồng bằng đến độ cao khoảng 1.800 m. Ăn chủ yếu là ếch nhái, cóc, thằn lằn và đôi khi cả rắn nhỏ. Đây là loài rắn răng sau có nọc độc, đồng thời sở hữu tuyến Nuchal ở vùng cổ giúp tích lũy độc tố từ thức ăn để tự vệ. Một số trường hợp bị cắn có thể gây rối loạn đông máu, vì vậy cần được theo dõi và điều trị tại cơ sở y tế.

2.3. Lý thuyết mô hình MachineLearning - XGBoost

Mô hình XGBoost (eXtreme Gradient Boosting) là mô hình học máy kết hợp dựa trên thuật toán cây quyết định (Decision Tree), được phát triển bởi Tianqi Chen và Carlos Guestrin (2016). Với mục tiêu cải thiện các hạn chế về tốc độ huấn luyện và khả năng tổng quát hóa của các mô hình Gradient Boosting truyền thống. Điểm nổi bật của XGBoost so với Gradient Boosting truyền thống là việc đưa thêm các thành phần chuẩn hóa vào hàm mục tiêu để tránh hiện tượng quá khớp. Với tập dữ liệu $D = \{(x_i, y_i)\}_{i=1}^n$, mô hình tập trung tìm kiếm bộ tham số để tối thiểu hóa hàm mục tiêu:

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

Trong đó: $l(\hat{y}_i, y_i)$ là hàm mất mát (loss function) giúp đo lường sai lệch giữa giá trị dự đoán và thực tế; $\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \|w\|^2$ (T là số lượng lá trên cây, w là trọng số của lá) dùng để kiểm soát độ phức tạp của mô hình cây quyết định f_k .

Quá trình huấn luyện của XGBoost được thực hiện theo cơ chế cộng dồn và sử dụng khai triển Taylor bậc hai để xấp xỉ hàm mục tiêu. Lúc này, bài toán sẽ chuyển về dạng đơn giản hơn và mỗi cây mới được xây dựng nhằm tối ưu phần sai số còn lại của các cây trước. Trên cơ sở đó, trọng số tối ưu tại mỗi nút lá được xác định dựa trên đạo hàm bậc nhất $g_i = \partial_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ và bậc hai $h_i = \partial_{\hat{y}^{(t-1)}}^2 l(y_i, \hat{y}^{(t-1)})$ của mất mát, đồng thời thuật toán áp dụng phương pháp tìm kiếm tham lam (greedy algorithm) để lựa chọn điểm chia nhánh tối ưu dựa trên mức độ giảm hàm mất mát.

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}$$

Kế thừa nền tảng toán học tối ưu, trong bối cảnh nghiên cứu của đề tài, XGBoost được thiết lập làm mô hình cơ sở. Mặc dù cấu trúc gốc của thuật toán cây quyết định được thiết kế cho dữ liệu dạng bảng, XGBoost vẫn đặc biệt phù hợp với bài toán phân loại hình ảnh khi kết hợp với bước trích xuất đặc trưng. Cụ thể, các đặc điểm sinh học phức tạp của loài rắn (như hình dáng đầu, màu sắc, kết cấu vảy) trên ảnh 2D sẽ được chuyển đổi thành các vector đặc trưng một chiều để đưa vào mô hình. Sức mạnh của mô hình XGBoost được phát huy tối đa nhờ khả năng mô hình hóa xuất sắc các tương tác phi tuyến tính giữa các biến đặc trưng hình ảnh. Thuật toán dễ dàng xử lý không gian dữ liệu nhiều chiều và chống lại hiện tượng quá khớp, thông qua các kỹ thuật như *shrinkage* và *column subsampling*. Đồng thời, cơ chế tối ưu hóa phân cứng và tìm kiếm điểm chia nhánh song song giúp mô hình duy trì tốc độ huấn luyện vượt trội ngay cả với tập dữ liệu ảnh quy mô lớn. Việc lựa chọn XGBoost đại diện cho nhóm phương pháp học máy truyền thống (Machine Learning) làm mô hình cơ sở sẽ tạo ra một hệ quy chiếu định lượng vững chắc. Sự đối chiếu này không chỉ giúp đánh giá khách quan giới hạn của việc phân loại dựa trên vector đặc trưng, mà còn làm bật lên ưu việt của mạng Học sâu (Deep Learning) đề xuất trong việc tự động học và hiểu các ngữ cảnh không gian phức tạp của loài rắn.


2.4. Lý thuyết mô hình Deep Learning - ViT

Vision Transformer (ViT) là một kiến trúc học sâu được phát triển dựa trên Transformer, vốn ban đầu được đề xuất cho các bài toán xử lý ngôn ngữ tự nhiên. Thay vì sử dụng các lớp tích chập như mạng CNN truyền thống, ViT khai thác cơ chế tự chú ý để học mối quan hệ giữa các vùng khác nhau trong ảnh, từ đó nắm bắt hiệu quả cả đặc trưng cục bộ và ngữ cảnh toàn cục. Nhờ khả năng biểu diễn mạnh mẽ, ViT đã đạt được nhiều kết quả nổi bật trong các nhiệm vụ phân loại ảnh và trở thành nền tảng cho nhiều nghiên cứu thị giác máy tính hiện đại như DeiT, Swin Transformer và DETR. Trong đó, ViT do Dosovitskiy và cộng sự đề xuất chia ảnh thành các patch, sau đó mã hóa thành vector và đưa vào Transformer để học đặc trưng, trước khi thực hiện phân loại bằng mạng MLP.

Quy trình luân chuyển và xử lý dữ liệu trong mô hình ViT được thực hiện một cách tuần tự theo các bước cốt lõi sau:

Đầu tiên, hình ảnh đầu vào được chia tách thành các mảnh ảnh nhỏ hơn có kích thước cố định. Các mảnh ảnh này được trải phẳng và đưa qua một lớp chiếu tuyến tính để chuyển đổi thành một chuỗi các vector nhúng mảnh ảnh. Nhằm bù đắp cho việc thiếu hụt tính tuần tự của cơ chế tự chú ý, thông tin không gian và vị trí tương đối của các mảnh ảnh sẽ được tích hợp thông qua việc cộng thêm các vector nhúng vị trí.

Chuỗi các vector nhúng này tiếp tục được truyền qua một chuỗi các lớp Transformer Encoder xếp chồng lên nhau, giúp mô hình học được các đặc trưng mang tính tổng thể và nắm bắt ngữ cảnh toàn cục của toàn bộ bức ảnh. Cuối cùng, vector biểu diễn của token phân loại ([CLS]) được đưa vào bộ phân loại MLP để dự đoán nhãn đầu ra. Quy trình tổng quát của mô hình được minh họa trong Hình 2.4.




Hình 2.4a. Sơ đồ kiến trúc mô hình Vision Transformer (ViT) để phân loại các giai đoạn bệnh Alzheimer từ ảnh MRI não

Nền tảng của Vision Transformer (ViT) là cơ chế tự chú ý (Self-Attention), được kế thừa từ kiến trúc Transformer do Ashish Vaswani và cộng sự đề xuất vào năm 2017. Cơ chế này cho phép mô hình học các mối quan hệ phụ thuộc giữa các phần tử trong chuỗi đầu vào, từ đó khai thác hiệu quả thông tin ngữ cảnh toàn cục của ảnh. Để áp dụng cơ chế tự chú ý vào một bức

ảnh X , chúng ta có thể sử dụng một mô hình cụ thể bao gồm việc biến đổi đầu vào để thu được ma trận truy vấn (Q), khóa (K), và giá trị (V). Phép biến đổi này có thể được biểu diễn dưới dạng toán học bằng công thức tiêu chuẩn cho Q , K và V , như được thể hiện trong Phương trình (1):

$$K = W^K X, \quad Q = W^Q X, \quad V = W^V X$$



Hình 2.4b. Sơ đồ cơ chế Scaled Dot-Product Attention và Multi-Head Attention trong kiến trúc Transformer

Cơ chế Chú ý tích vô hướng có tỷ lệ bao gồm việc tính tích vô hướng của một vector truy vấn với một nhóm các vector khóa, sau đó tỷ lệ hóa kết quả cho căn bậc hai của số chiều vector khóa và sử dụng hàm softmax để tính tổng có trọng số của các vector giá trị. Chúng ta có thể biểu diễn cơ chế chú ý tích vô hướng có tỷ lệ qua Phương trình (2):

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

trong đó (d_k) là số chiều của vector khóa. Ma trận $\left(\frac{QK^T}{\sqrt{d_k}}\right)$ biểu diễn mức độ tương quan giữa các phần tử đầu vào và được sử dụng để tính trọng số chú ý.

Để tăng khả năng biểu diễn đặc trưng, Transformer sử dụng cơ chế Chú ý đa đầu (Multi-Head Attention), thực hiện nhiều phép tính Self-Attention song song với các bộ tham số khác nhau như trong Phương trình (3):

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

$$Attention(W_i^Q X, W_i^K X, W_i^V X)$$

Nhờ đó, mô hình có thể đồng thời học được nhiều loại quan hệ và đặc trưng ở các không gian biểu diễn khác nhau, góp phần nâng cao hiệu quả nhận dạng và phân loại ảnh.

2.5. Cơ chế giải thích Attention Rollout cho mạng Transformer

Sự phát triển mạnh mẽ của các mô hình Deep Learning đã mang lại nhiều cải tiến về hiệu năng trong các bài toán thị giác máy tính. Tuy nhiên, một trong những hạn chế lớn nhất của các mô hình này là tính khó giải thích (black-box), khi người dùng chỉ quan sát được kết quả đầu ra mà khó xác định được quá trình ra quyết định bên trong mô hình. Vấn đề này trở nên đặc biệt quan trọng trong các lĩnh vực có yêu cầu cao về độ tin cậy như y tế, sinh học, bảo

tồn động vật hoang dã và hỗ trợ ra quyết định. Trong bối cảnh đó, lĩnh vực Trí tuệ nhân tạo có khả năng giải thích (Explainable Artificial Intelligence - XAI) đã được phát triển nhằm cung cấp các công cụ và phương pháp giúp người dùng hiểu rõ hơn cơ sở mà mô hình sử dụng để đưa ra dự đoán (Arrieta et al., 2020).

Đối với các mô hình Transformer, cơ chế Attention được xem là thành phần cốt lõi quyết định khả năng học biểu diễn của mô hình. cơ chế Attention là thành phần cốt lõi giúp mô hình học mối quan hệ giữa các phần tử đầu vào (Vaswani et al., 2017). Trong Vision Transformer (ViT), ảnh được chia thành các patch và biểu diễn dưới dạng token, sau đó được xử lý qua nhiều lớp Multi-Head Self-Attention để học các đặc trưng toàn cục. Tuy nhiên, do Attention được tính toán qua nhiều lớp và nhiều đầu chú ý, việc xác định chính xác vùng ảnh ảnh hưởng đến quyết định cuối cùng của mô hình vẫn là một thách thức đáng kể.

Nhằm giải quyết vấn đề này, Abnar và Zuidema (2020) đã đề xuất phương pháp Attention Rollout, cho phép xem xét Attention tại từng lớp riêng lẻ mà còn theo dõi luồng thông tin được truyền qua toàn bộ các lớp Attention trong mạng. Theo các tác giả, Attention ở một lớp không phản ánh đầy đủ mức độ ảnh hưởng của một token tới đầu ra cuối cùng bởi thông tin còn tiếp tục được lan truyền qua nhiều lớp kế tiếp. Do đó, cần phải tổng hợp ảnh hưởng của tất cả các lớp để xác định chính xác mức độ đóng góp của từng token đầu vào.

Giả sử ma trận Attention tại lớp thứ l là $A(l)$. Do sự tồn tại của các kết nối tắt trong kiến trúc Transformer, Attention Rollout trước tiên bổ sung ma trận đơn vị I vào ma trận Attention nhằm phản ánh luồng thông tin được truyền trực tiếp qua kết nối residual. Ma trận Attention hiệu chỉnh được xác định như sau:

$$\tilde{A}^{(l)} = \frac{A^{(l)} + I}{2}$$

Trong đó: $A^{(l)}$ là ma trận Attention tại lớp thứ l ; I là ma trận đơn vị cùng kích thước; $\tilde{A}^{(l)}$ là ma trận Attention sau khi đã tính đến ảnh hưởng của kết nối residual. Sau khi chuẩn hóa, ảnh hưởng tích lũy của các token qua nhiều lớp được tính bằng phép nhân liên tiếp các ma trận Attention hiệu chỉnh: $R^{(L)} = \tilde{A}^{(L)} \tilde{A}^{(L-1)} \dots \tilde{A}^{(1)}$

Trong đó, $R^{(L)}$ biểu diễn mức độ ảnh hưởng cuối cùng của các token đầu vào tới token phân loại ([CLS]) sau khi thông tin đã lan truyền qua toàn bộ mạng. Đối với ViT, mỗi token tương ứng với một patch ảnh trong không gian đầu vào, do đó các giá trị Rollout có thể được ánh xạ ngược về ảnh gốc để tạo thành bản đồ nhiệt (Attention Map). Các vùng có giá trị Attention cao thể hiện những khu vực được mô hình tập trung nhiều nhất khi đưa ra dự đoán, qua đó hỗ trợ đánh giá tính hợp lý của các đặc trưng mà mô hình đã học.

So với các phương pháp giải thích phổ biến khác như Grad-CAM (Selvaraju et al., 2017), Attention Rollout có ưu điểm là khai thác trực tiếp cơ chế Self-Attention vốn đã tồn tại trong Transformer mà không yêu cầu tính gradient hoặc thay đổi kiến trúc mô hình. Điều này giúp quá trình giải thích trở nên đơn giản hơn và phù hợp với các mô hình Vision Transformer. Nhiều nghiên cứu sau đó đã sử dụng Attention Rollout như một công cụ trực quan hóa tiêu chuẩn để phân tích hành vi của Transformer trong các bài toán phân loại ảnh, nhận dạng sinh vật và chẩn đoán y khoa.

Attention Rollout được sử dụng nhằm trực quan hóa các vùng ảnh mà mô hình Vision Transformer tập trung khi thực hiện hai nhiệm vụ gồm phân loại độc tính và phân loại họ rắn. Các bản đồ Attention được sử dụng như một công cụ hỗ trợ đánh giá tính hợp lý của mô hình, giúp kiểm tra liệu hệ thống có thực sự chú ý đến các đặc điểm hình thái quan trọng của rắn như đầu, mắt, hoa văn vảy hoặc cấu trúc cơ thể hay không. Điều này góp phần nâng cao tính minh bạch và độ tin cậy của hệ thống nhận diện rắn độc được đề xuất.

2.6. Cơ sở y khoa về nọc độc và sơ cấp cứu

2.6.1. Cơ sở y khoa về nọc độc rắn

Nọc độc rắn là một hỗn hợp sinh học phức tạp được tiết ra từ các tuyến nọc nằm phía sau mắt của rắn độc và được đưa vào cơ thể con mồi hoặc nạn nhân thông qua hệ thống răng nanh chuyên biệt. Về bản chất, nọc độc là tập hợp của nhiều loại enzyme, protein, polypeptide và các phân tử có hoạt tính sinh học cao. Chức năng sinh học tự nhiên của nọc độc là làm bất động con mồi, hỗ trợ quá trình săn mồi và tiêu hóa thức ăn. Khi đi vào cơ thể người, các thành phần này có thể gây tổn thương nghiêm trọng đến nhiều cơ quan khác nhau tùy thuộc vào thành phần độc tố và lượng nọc được tiêm vào. Các nghiên cứu y học cho thấy nọc độc rắn thường gây tác động theo ba cơ chế chính: tác động lên hệ thần kinh, hệ tuần hoàn - đông máu và hệ cơ.

Độc tố thần kinh (Neurotoxin) thường gặp ở các loài thuộc họ Elapidae như rắn hổ, rắn hổ mang, rắn cạp nong và rắn cạp nia. Các độc tố này tác động lên các khớp nối thần kinh - cơ, làm gián đoạn quá trình dẫn truyền xung thần kinh đến cơ vân. Hậu quả là bệnh nhân xuất hiện các triệu chứng như sụp mi mắt, nhìn đôi, khó nuốt, yếu cơ, nói khó và tiến triển đến liệt cơ hô hấp nếu không được điều trị kịp thời. Suy hô hấp là nguyên nhân tử vong hàng đầu trong các trường hợp ngộ độc thần kinh do rắn cắn.

Độc tố huyết học (Hemotoxin) thường xuất hiện ở các loài thuộc họ Viperidae như rắn lục xanh, rắn lục đuôi đỏ và rắn chàm quạp. Nhóm độc tố này gây tổn thương thành mạch máu, phá hủy các yếu tố đông máu và làm rối loạn quá trình cầm máu tự nhiên của cơ thể. Bệnh nhân có thể xuất hiện các biểu hiện như chảy máu chân răng, xuất huyết dưới da, tiểu máu hoặc xuất huyết nội tạng. Trong những trường hợp nặng, rối loạn đông máu kéo dài có thể dẫn đến sốc mất máu hoặc suy đa cơ quan.

Độc tố cơ (Myotoxin) thường gặp ở rắn biển và một số loài rắn cạp nia. Độc tố này trực tiếp phá hủy các tế bào cơ vân, giải phóng myoglobin vào máu. Khi nồng độ myoglobin tăng cao, thận phải hoạt động quá mức để đào thải chất này, từ đó làm tăng nguy cơ suy thận cấp. Bệnh nhân thường có các biểu hiện như đau cơ toàn thân, cứng cơ, yếu cơ, nước tiểu sẫm màu và có thể tiến triển thành suy thận hoặc ngừng tim nếu không được điều trị kịp thời.



Hình 2.6.1. Mức độ nặng nhất của một vết thương khi bị rắn cắn - Hoại tử

Ngoài các tác động toàn thân, nọc độc còn gây tổn thương tại chỗ ở vùng bị cắn. Những biểu hiện thường gặp bao gồm đau, sưng nề, bầm tím, chảy máu, nổi bóng nước và hoại tử mô. Mức độ tổn thương phụ thuộc vào lượng nọc được tiêm vào cơ thể cũng như vị trí vết cắn. Mức độ nặng của một ca rắn cắn không chỉ phụ thuộc vào loài rắn mà còn liên quan đến nhiều yếu tố khác như lượng nọc độc được tiêm vào, vị trí vết cắn, tuổi và thể trạng nạn nhân, thời gian vận chuyển đến cơ sở y tế cũng như các biện pháp sơ cứu ban đầu. Do đó, việc nhận diện sớm loài rắn và đánh giá nguy cơ nhiễm độc có ý nghĩa rất quan trọng trong quá trình điều trị.

2.6.2. Cơ sở y khoa về sơ cấp cứu khi bị rắn cắn

Sơ cấp cứu là giai đoạn xử lý ban đầu ngay sau khi xảy ra tai nạn rắn cắn nhằm hạn chế sự lan truyền của nọc độc và duy trì tình trạng ổn định của nạn nhân trước khi tiếp cận cơ sở y tế. Theo các hướng dẫn điều trị hiện hành, mục tiêu quan trọng nhất của sơ cứu là làm chậm quá trình hấp thu nọc độc, giảm nguy cơ biến chứng và bảo đảm bệnh nhân được vận chuyển an toàn đến bệnh viện.

Về mặt sinh lý học, phần lớn nọc độc rắn sau khi được tiêm vào mô dưới da sẽ lan truyền thông qua hệ bạch huyết trước khi đi vào tuần hoàn máu. Quá trình này chịu ảnh hưởng lớn bởi hoạt động co cơ của cơ thể. Khi nạn nhân đi lại hoặc vận động nhiều, các cơn co cơ sẽ thúc đẩy dòng bạch huyết lưu thông nhanh hơn, khiến nọc độc lan rộng đến các cơ quan trong thời gian ngắn hơn. Đây là lý do vì sao các hướng dẫn y khoa đều khuyến cáo hạn chế tối đa vận động sau khi bị rắn cắn. Biện pháp sơ cứu quan trọng nhất là trấn an nạn nhân và giữ người bệnh ở trạng thái nghỉ ngơi. Tâm lý hoảng loạn có thể làm tăng nhịp tim và huyết áp, từ đó gián tiếp thúc đẩy sự phân bố của nọc độc trong cơ thể. Sau đó, chi bị cắn cần được bất động bằng nẹp hoặc các vật liệu tương tự để hạn chế cử động cơ học.

*** Sơ cứu chung**

Khi xảy ra tai nạn rắn cắn, nguyên tắc quan trọng nhất là giữ bình tĩnh và nhanh chóng đưa nạn nhân đến cơ sở y tế gần nhất. Nạn nhân cần được đặt nằm yên, hạn chế tối đa vận động, đặc biệt là vùng chi bị cắn, nhằm làm chậm quá trình lan truyền nọc độc trong cơ thể. Chi bị cắn nên được giữ ở vị trí thấp hơn tim và các vật dụng như nhẫn, vòng tay, đồng hồ hoặc giày dép cần được tháo bỏ sớm để tránh tình trạng chèn ép khi sưng nề xuất hiện. Vết cắn có thể

được rửa nhẹ nhàng bằng nước sạch và xà phòng, sau đó che phủ bằng gạc sạch để hạn chế nhiễm trùng. Trong trường hợp nạn nhân có biểu hiện suy hô hấp hoặc ngừng thở, cần tiến hành hô hấp nhân tạo và gọi cấp cứu ngay lập tức. Nếu có thể thực hiện an toàn, nên chụp ảnh con rắn từ khoảng cách phù hợp hoặc ghi nhớ các đặc điểm nhận dạng như màu sắc, hoa văn, hình dạng đầu và kích thước cơ thể. Những thông tin này sẽ hỗ trợ bác sĩ xác định loại rắn gây cắn và lựa chọn hướng điều trị phù hợp. Sau khi sơ cứu ban đầu, bệnh nhân cần được đưa đến cơ sở y tế trong thời gian sớm nhất. Tại bệnh viện, bác sĩ sẽ đánh giá mức độ nhiễm độc, theo dõi các dấu hiệu thần kinh, tuần hoàn và hô hấp, đồng thời chỉ định sử dụng huyết thanh kháng nọc nếu cần thiết. Hiện nay, huyết thanh kháng nọc là phương pháp điều trị đặc hiệu duy nhất có khả năng trung hòa độc tố trong cơ thể người bị rắn độc cắn.

** Sơ cứu khi bị rắn hổ cắn (Hổ mang, Cạp nong, Cạp nia)*

Nhóm rắn hổ thường chứa độc tố thần kinh mạnh, có khả năng gây liệt cơ và suy hô hấp trong thời gian ngắn. Do nọc độc chủ yếu lan truyền qua hệ bạch huyết, mục tiêu sơ cứu là làm chậm quá trình phát tán nọc độc đến tuần hoàn trung tâm.

Biện pháp được khuyến cáo là băng ép bất động. Trước tiên, sử dụng băng thun hoặc vải sạch bản rộng băng từ đầu chi về phía gốc chi, phủ toàn bộ vùng bị cắn. Băng cần đủ chặt để hạn chế lưu thông bạch huyết nhưng không được quá chặt gây cản trở tuần hoàn động mạch; người sơ cứu vẫn phải sờ được mạch hoặc có thể luồn một ngón tay dưới lớp băng. Sau đó, dùng nẹp cứng để cố định hoàn toàn chi bị cắn nhằm hạn chế vận động. Trong suốt quá trình vận chuyển đến bệnh viện, băng ép và nẹp cố định cần được giữ nguyên.

** Sơ cứu khi bị rắn lục cắn (Lục xanh, Lục đuôi đỏ và các loài tương tự)*

Nọc độc của rắn lục chủ yếu gây tổn thương mô tại chỗ, rối loạn đông máu và xuất huyết. Khác với rắn hổ, việc băng ép chặt hoặc garô có thể làm tăng áp lực mô, gây thiếu máu nuôi dưỡng và làm nặng thêm tình trạng hoại tử. Do đó, tuyệt đối không sử dụng garô hoặc băng ép chặt khi nghi ngờ bị rắn lục cắn. Vết thương chỉ cần được che phủ nhẹ bằng gạc sạch để phòng ngừa nhiễm trùng. Chi bị cắn nên được cố định bằng nẹp ở tư thế thoải mái nhằm giảm vận động cơ và hạn chế lan truyền nọc độc. Sau khi sơ cứu ban đầu, nạn nhân cần được đưa đến cơ sở y tế càng sớm càng tốt để theo dõi tình trạng đông máu và điều trị bằng huyết thanh kháng nọc khi có chỉ định.

** Những việc không nên làm*

Nhiều phương pháp sơ cứu dân gian vẫn còn được sử dụng sau khi bị rắn cắn như rạch vết thương để hút nọc, đắp lá thuốc, chườm nóng, chườm lạnh hoặc bôi hóa chất lên vùng bị cắn. Tuy nhiên, theo các nghiên cứu y khoa, những biện pháp này không làm giảm lượng nọc độc trong cơ thể mà còn làm tăng nguy cơ nhiễm trùng, chảy máu, hoại tử mô và các biến chứng nghiêm trọng khác. Do đó, các hướng dẫn điều trị hiện đại đều khuyến cáo không can thiệp trực tiếp vào vết cắn, đồng thời không sử dụng đá lạnh, nhiệt nóng hoặc garô khi chưa xác định chính xác loại rắn gây cắn. Trong một số trường hợp, kỹ thuật băng ép bất động có thể được áp dụng nhằm làm chậm sự lan truyền của nọc độc qua hệ bạch huyết. Tuy nhiên, phương pháp này cần được thực hiện đúng kỹ thuật và không phù hợp với tất cả các loại rắn độc.

Từ những cơ sở y khoa trên có thể thấy rằng việc nhận diện chính xác loài rắn ngay từ giai đoạn đầu có ý nghĩa rất lớn trong lựa chọn hướng xử trí và điều trị. Đây cũng chính là cơ

sở thực tiễn cho việc phát triển các hệ thống nhận diện rắn bằng trí tuệ nhân tạo nhằm hỗ trợ người dùng nhận biết nguy cơ và tiếp cận các biện pháp xử lý phù hợp trong thời gian sớm nhất.

CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Thu thập và tiền xử lý dữ liệu

3.1.1. Xây dựng và tổ chức bộ dữ liệu

Dựa vào cơ sở dữ liệu Trang Sinh vật rừng Việt Nam (vncreatures), nghiên cứu tiến hành thu thập trên 7 nhóm họ rắn bao gồm khoảng 85 loài, thu được khoảng 4153 ảnh. Dữ liệu hình ảnh được thu thập từ hai nguồn chính gồm nền tảng iNaturalist và hoạt động khảo sát thực tế tại Trại rắn Đồng Tâm.

Nguồn dữ liệu thứ nhất được thu thập từ nền tảng iNaturalist, một cơ sở dữ liệu đa dạng sinh học trực tuyến được sử dụng rộng rãi trong các nghiên cứu về nhận dạng loài và thị giác máy tính. iNaturalist cho phép người dùng trên toàn thế giới chia sẻ các quan sát sinh vật kèm theo hình ảnh, vị trí địa lý và thông tin phân loại. Trong nghiên cứu này, nhóm sử dụng API của iNaturalist để truy xuất các bản ghi quan sát thuộc lớp Bò sát (Reptilia), tập trung vào các họ rắn xuất hiện tại Việt Nam. Các truy vấn được thực hiện thông qua API quan sát (Observations API), lọc dữ liệu theo tên khoa học, cấp phân loại, chất lượng quan sát và trạng thái xác thực của mẫu.

Bên cạnh dữ liệu trực tuyến, nhóm còn thực hiện thu thập dữ liệu thực tế tại Trại rắn Đồng Tâm, tỉnh Đồng Tháp. Đây là một trong những cơ sở nghiên cứu và bảo tồn rắn lớn tại Việt Nam, lưu giữ nhiều loài rắn độc và không độc đặc trưng của khu vực Nam Bộ. Trong quá trình khảo sát, nhóm trực tiếp chụp ảnh các cá thể rắn ở nhiều góc độ khác nhau nhằm ghi nhận đa dạng đặc điểm hình thái như đầu, thân, hoa văn và màu sắc. Các ảnh thu thập thực địa có ưu điểm là chất lượng cao, thông tin nhận được xác nhận bởi cán bộ chuyên môn tại trại rắn và phản ánh sát điều kiện thực tế tại Việt Nam. Nguồn dữ liệu này đóng vai trò quan trọng trong việc bổ sung cho dữ liệu thu thập từ Internet, giúp tăng tính đa dạng và độ tin cậy của bộ dữ liệu huấn luyện.

Mỗi ảnh được lưu kèm đường dẫn truy cập và các thuộc tính phân loại như trạng thái độc tính, họ và loài rắn. Sau khi hoàn tất quá trình thu thập, dữ liệu được chuyển thành DataFrame bằng thư viện Pandas. DataFrame giúp chuẩn hóa dữ liệu đầu vào, đồng thời tạo điều kiện thuận lợi cho các thao tác thống kê, phân tích và chia tập dữ liệu ở các bước tiếp theo.

Trong quá trình thực nghiệm, nhóm nghiên cứu đã xây dựng bộ dữ liệu chuẩn hóa gồm 4.153 ảnh, đây là quy mô dữ liệu chính thức được hệ thống học sâu Vision Transformer (ViT) khai thác trọn vẹn. Đối với mô hình cơ sở XGBoost, dù khâu tiền xử lý quét được 4.183 ảnh do bao gồm cả một số ảnh biến thể, crop được tạo ra để tăng cường đặc trưng hình học, nhưng khi đưa vào huấn luyện thực tế, số lượng mẫu giảm xuống còn 4.179 ảnh. Sự chênh lệch này là kết quả của việc áp dụng các bộ lọc thủ công (CLAHE, HOG, HSV), hệ thống đã phát hiện và loại bỏ 4 vector đặc trưng lỗi (do ảnh bị nhiễu hạt nặng hoặc thiếu cấu trúc hình học) để bảo toàn tính toàn vẹn của không gian đặc trưng. Việc giảm nhẹ số lượng mẫu ở mô hình truyền thống là hệ quả kỹ thuật tất yếu nhằm đảm bảo tính ổn định của quá trình hội tụ, hoàn toàn không làm sai lệch phân phối lớp hay ảnh hưởng đến tính khách quan khi đối sánh hiệu năng giữa hai phương pháp tiếp cận.

 Tổng ảnh: 4153

--- Label họ (9 nhãn) ---

```
[0] Họ rắn lục Viperidae: 870 ảnh
[1] Rắn biển Hydrophiidae_doc: 277 ảnh
[2] Rắn biển Hydrophiidae_khongdoc: 28 ảnh
[3] Rắn giun Typhlopidae: 82 ảnh
[4] Rắn hổ Elapidae: 665 ảnh
[5] Rắn hổ biển Laticaudinae: 70 ảnh
[6] Rắn nước Colubridae_doc: 200 ảnh
[7] Rắn nước Colubridae_khongdoc: 1911 ảnh
[8] Rắn trun Cyndrophiiidae: 50 ảnh
```

--- Label độc ---

```
Độc (1)      : 2082
Không độc (0): 2071
```

--- Mất cân bằng cần xử lý ---

```
Max: 1911, Min: 28, Tỉ lệ: 68.2:1
```

Hình 3.1.1. Mô tả thống kê cho tập dữ liệu hình ảnh rắn

Kết quả thống kê cho thấy bộ dữ liệu gồm 4.153 ảnh, trong đó có 2.082 ảnh rắn độc và 2.071 ảnh rắn không độc. Tỷ lệ giữa hai nhóm gần như cân bằng (50,13% và 49,87%), cho thấy dữ liệu của bài toán phân loại độc tính không gặp vấn đề mất cân bằng đáng kể ở cấp độ nhị phân. Điều này tạo điều kiện thuận lợi cho quá trình huấn luyện mô hình phân loại độc và không độc.

Đối với bài toán phân loại họ rắn, sau khi tách hai họ xuất hiện ở cả nhóm độc và không độc là Hydrophiidae và Colubridae, bộ dữ liệu được chia thành 9 lớp phân loại. Kết quả cho thấy sự phân bố số lượng ảnh giữa các lớp không đồng đều. Lớp có số lượng ảnh lớn nhất là Rắn nước Colubridae_khongdoc với 1.911 ảnh, chiếm khoảng 46% tổng số dữ liệu. Trong khi đó, lớp có số lượng ảnh nhỏ nhất là Rắn biển Hydrophiidae_khongdoc với chỉ 28 ảnh. Ngoài ra, một số lớp như Typhlopidae (82 ảnh), Laticaudinae (70 ảnh) và Cyndrophiiidae (50 ảnh) có số lượng mẫu tương đối hạn chế. Điều này làm tăng nguy cơ mô hình học chưa đầy đủ các đặc trưng của các lớp này. Sự chênh lệch giữa lớp lớn nhất và lớp nhỏ nhất đạt khoảng 68,2:1, phản ánh hiện tượng mất cân bằng dữ liệu khá nghiêm trọng ở bài toán phân loại họ rắn. Nếu không có biện pháp xử lý phù hợp, mô hình có xu hướng ưu tiên học các lớp có nhiều dữ liệu và bỏ qua các lớp thiểu số, dẫn đến độ chính xác tổng thể có thể cao nhưng hiệu quả nhận diện các lớp ít dữ liệu lại thấp. Vì vậy, nghiên cứu áp dụng kỹ thuật Weighted Random Sampler trong quá trình huấn luyện nhằm tăng tần suất xuất hiện của các lớp thiểu số, giúp mô hình học cân bằng hơn trên toàn bộ 9 lớp phân loại.

3.1.2. Gán nhãn và mã hóa dữ liệu

Trước tiên, cột **label_doc** được tạo ra nhằm biểu diễn trạng thái độc tính của từng mẫu dữ liệu. Những ảnh thuộc nhóm rắn độc được gán giá trị 1, trong khi các ảnh thuộc nhóm rắn không độc được gán giá trị 0. Đây là nhãn mục tiêu cho bài toán phân loại độc tính.

Tuy nhiên, khi khảo sát bộ dữ liệu, tác giả nhận thấy hai họ rắn là Rắn biển Hydrophiidae và Rắn nước Colubridae xuất hiện ở cả nhóm rắn độc và nhóm rắn không độc. Nếu chỉ sử dụng tên họ rắn làm nhãn, các mẫu dữ liệu có đặc điểm sinh học khác nhau nhưng cùng thuộc một họ sẽ bị gộp chung vào một lớp. Điều này có thể gây nhiễu trong quá trình huấn luyện và làm

giảm khả năng phân biệt của mô hình. Để khắc phục vấn đề trên, nghiên cứu thực hiện tách riêng các họ xuất hiện ở cả hai nhóm bằng cách bổ sung hậu tố thể hiện trạng thái độc tính. Cụ thể, các mẫu thuộc họ Hydrophiidae và Colubridae sẽ được chia thành hai lớp độc lập là `_doc` và `_khongdoc`. Ví dụ, lớp "Rắn nước Colubridae" được tách thành hai nhãn riêng biệt là "Rắn nước Colubridae_doc" và "Rắn nước Colubridae_khongdoc". Nhờ đó, mỗi lớp dữ liệu mang đặc trưng rõ ràng và đồng nhất hơn.

Sau khi hoàn tất quá trình tách nhãn, tất cả các lớp được liệt kê và mã hóa thành các giá trị số nguyên thông qua phương pháp Label Encoding. Mỗi lớp được gán một chỉ số duy nhất để phục vụ quá trình huấn luyện mô hình học sâu. Kết quả cuối cùng tạo ra 9 lớp phân loại khác nhau thay vì 7 lớp ban đầu, giúp mô hình học được sự khác biệt giữa các nhóm rắn có cùng họ nhưng khác trạng thái độc tính. Việc thiết kế nhãn theo cách này không chỉ phản ánh chính xác đặc điểm của bộ dữ liệu mà còn giúp nâng cao chất lượng học tập của mô hình, giảm hiện tượng chồng chéo giữa các lớp và cải thiện hiệu quả phân loại trong giai đoạn huấn luyện.

3.1.3. Phân chia tập dữ liệu

Mục tiêu của bước này là đảm bảo mô hình được đánh giá trên các mẫu dữ liệu chưa từng xuất hiện trong quá trình huấn luyện, từ đó phản ánh chính xác khả năng tổng quát hóa của mô hình đối với dữ liệu thực tế.

```
SEED = 42
# --- Split 70/15/15 stratify theo label_ho (đảm bảo đủ 9 họ ở mỗi tập) ---
train_df, temp_df = train_test_split(
    df, test_size=0.30, random_state=SEED, stratify=df['label_ho']
)
val_df, test_df = train_test_split(
    temp_df, test_size=0.50, random_state=SEED, stratify=temp_df['label_ho']
)
train_df = train_df.reset_index(drop=True)
val_df = val_df.reset_index(drop=True)
test_df = test_df.reset_index(drop=True)
print(f"Train: {len(train_df)} | Val: {len(val_df)} | Test: {len(test_df)}")
```

Bộ dữ liệu được chia thành ba tập gồm tập huấn luyện (Training Set), tập xác thực (Validation Set) và tập kiểm tra (Test Set) theo tỷ lệ lần lượt là 70%, 15% và 15%. Tỷ lệ này được lựa chọn nhằm đảm bảo mô hình có đủ dữ liệu để học các đặc trưng của đối tượng trong khi vẫn duy trì số lượng mẫu cần thiết cho quá trình đánh giá. Quá trình phân chia được thực hiện bằng phương pháp Stratified Sampling dựa trên nhãn `label_ho`. Phương pháp này đảm bảo tỷ lệ xuất hiện của cả 9 lớp dữ liệu được duy trì tương đối đồng đều trong các tập Train, Validation và Test. Điều này đặc biệt quan trọng đối với bộ dữ liệu nghiên cứu vì một số lớp có số lượng ảnh khá ít so với các lớp còn lại. Nếu sử dụng phương pháp chia ngẫu nhiên thông thường, một số lớp thiểu số có thể không xuất hiện hoặc xuất hiện với số lượng quá ít trong tập Validation hoặc Test, dẫn đến kết quả đánh giá không phản ánh đúng năng lực của mô hình.

Bên cạnh đó, tham số `random_state = 42` được thiết lập nhằm cố định quá trình sinh số ngẫu nhiên khi chia dữ liệu. Điều này giúp đảm bảo kết quả phân chia luôn được tái lập trong các lần thực nghiệm khác nhau, góp phần nâng cao tính tin cậy và khả năng kiểm chứng của nghiên cứu. Sau khi hoàn tất quá trình phân chia, chỉ số của các DataFrame được thiết lập lại

thông qua hàm `reset_index()`. Bước này giúp dữ liệu được sắp xếp liên tục từ 0 đến $n-1$, thuận tiện cho quá trình truy xuất và xây dựng bộ dữ liệu trong PyTorch ở các giai đoạn tiếp theo.

3.1.4. Tiền xử lý và tăng cường dữ liệu ảnh

Dữ liệu ảnh thu thập từ nhiều nguồn khác nhau thường có sự khác biệt về kích thước, góc chụp, điều kiện ánh sáng và chất lượng hình ảnh. Nếu đưa trực tiếp các ảnh này vào mô hình, sự không đồng nhất của dữ liệu có thể làm giảm hiệu quả học tập và khả năng tổng quát hóa của mô hình. Vì vậy, nghiên cứu tiến hành tiền xử lý và tăng cường dữ liệu nhằm chuẩn hóa dữ liệu đầu vào, đồng thời tạo ra nhiều biến thể khác nhau của ảnh huấn luyện để giúp mô hình học được các đặc trưng ổn định hơn.

```
train_transform = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.RandomHorizontalFlip(),
    transforms.RandomVerticalFlip(),
    transforms.ColorJitter(brightness=0.2, contrast=0.2, saturation=0.2),
    transforms.ToTensor(),
    transforms.Normalize([0.485, 0.456, 0.406],
                        [0.229, 0.224, 0.225]),
])
val_transform = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.ToTensor(),
    transforms.Normalize([0.485, 0.456, 0.406],
                        [0.229, 0.224, 0.225]),
])
```

Tất cả ảnh trong bộ dữ liệu được thay đổi kích thước về 224×224 pixel thông qua phép biến đổi `Resize`. Kích thước này được lựa chọn nhằm phù hợp với kiến trúc Vision Transformer được sử dụng trong nghiên cứu. Việc chuẩn hóa kích thước giúp đảm bảo tất cả ảnh đầu vào có cùng định dạng, đồng thời giảm chi phí tính toán trong quá trình huấn luyện.

Đối với tập huấn luyện, nghiên cứu áp dụng các kỹ thuật tăng cường dữ liệu nhằm tạo ra nhiều biến thể khác nhau từ cùng một ảnh gốc. Cụ thể, phép biến đổi `RandomHorizontalFlip` và `RandomVerticalFlip` được sử dụng để tạo ra các ảnh lật ngang hoặc lật dọc ngẫu nhiên. Điều này giúp mô hình học được các đặc trưng của đối tượng trong nhiều tư thế và góc quan sát khác nhau, hạn chế việc phụ thuộc vào một hướng xuất hiện cố định của đối tượng trong ảnh. Bên cạnh đó, phép biến đổi `ColorJitter` được sử dụng để thay đổi ngẫu nhiên độ sáng, độ tương phản và độ bão hòa màu sắc của ảnh. Bước này dùng để mô phỏng các điều kiện môi trường khác nhau như thay đổi ánh sáng, chất lượng camera hoặc điều kiện chụp thực tế. Nhờ đó, mô hình có khả năng thích nghi tốt hơn với các dữ liệu chưa từng xuất hiện trong quá trình huấn luyện. Sau khi hoàn thành các phép biến đổi hình ảnh, dữ liệu được chuyển sang định dạng Tensor thông qua hàm `ToTensor()`. Đây là định dạng dữ liệu chuẩn được thư viện PyTorch sử dụng để thực hiện các phép tính trên GPU và huấn luyện mô hình học sâu. Cuối cùng, các ảnh được chuẩn hóa bằng giá trị trung bình và độ lệch chuẩn của bộ dữ liệu ImageNet thông qua hàm `Normalize()`. Do mô hình Vision Transformer trong nghiên cứu sử dụng trọng số khởi tạo từ mô hình đã được huấn luyện trước trên ImageNet, việc chuẩn hóa theo cùng bộ tham số giúp dữ liệu đầu vào có phân bố tương đồng với dữ liệu mà mô hình đã học trước đó. Điều này góp phần cải thiện tốc độ hội tụ, tăng tính ổn định của quá trình huấn luyện và nâng cao hiệu quả học tập của mô hình.

Đối với tập xác thực (Validation Set) và tập kiểm tra (Test Set), nghiên cứu chỉ thực hiện thay đổi kích thước, chuyển đổi Tensor và chuẩn hóa dữ liệu mà không áp dụng các phép tăng cường dữ liệu. Điều này nhằm đảm bảo rằng kết quả đánh giá phản ánh chính xác hiệu suất thực tế của mô hình trên dữ liệu gốc, tránh ảnh hưởng từ các biến đổi ngẫu nhiên trong quá trình kiểm thử.

3.1.5. Cân bằng dữ liệu bằng Weighted Random Sampler

Để giảm ảnh hưởng của hiện tượng mất cân bằng dữ liệu giữa các họ, nghiên cứu sử dụng kỹ thuật Weighted Random Sampler trong quá trình huấn luyện. Phương pháp này giúp tăng tần suất xuất hiện của các mẫu thuộc lớp thiểu số mà không làm thay đổi cấu trúc hoặc số lượng thực tế của bộ dữ liệu.

```
ho_counts_train = train_df['label_ho'].value_counts()
class_weights   = 1.0 / ho_counts_train.sort_index().values
sample_weights  = train_df['label_ho'].map(
    lambda x: class_weights[x]
).values
sampler = WeightedRandomSampler(
    weights      = torch.DoubleTensor(sample_weights),
    num_samples = len(train_df),
    replacement = True)
```


Nghiên cứu tiến hành thống kê số lượng mẫu của từng lớp trong tập huấn luyện thông qua biến `ho_counts_train`. Từ kết quả thống kê này, trọng số của mỗi lớp được tính theo công thức:

$$w_i = \frac{1}{n_i}$$

Trong đó: w_i là trọng số của lớp thứ (i); n_i là số lượng mẫu thuộc lớp thứ (i).

Theo công thức trên, các lớp có ít dữ liệu sẽ nhận được trọng số lớn hơn, trong khi các lớp có nhiều dữ liệu sẽ nhận được trọng số nhỏ hơn. Cách tính này giúp cân bằng xác suất lựa chọn giữa các lớp trong quá trình huấn luyện. Sau khi xác định trọng số của từng lớp, chương trình gán trọng số tương ứng cho từng mẫu dữ liệu thông qua biến `sample_weights`. Như vậy, mỗi ảnh trong tập huấn luyện sẽ mang một trọng số phụ thuộc vào lớp mà nó thuộc về. Bộ lấy mẫu `WeightedRandomSampler` được xây dựng dựa trên danh sách trọng số vừa tính toán. Trong mỗi epoch, bộ lấy mẫu sẽ ưu tiên lựa chọn các mẫu thuộc lớp thiểu số với xác suất cao hơn so với các lớp chiếm đa số. Nhờ đó, mô hình được tiếp xúc thường xuyên hơn với các lớp có ít dữ liệu và có cơ hội học được đầy đủ đặc trưng của tất cả các lớp. Tham số `replacement=True` cho phép một mẫu dữ liệu có thể được lựa chọn nhiều lần trong cùng một epoch. Điều này đặc biệt hữu ích đối với các lớp có số lượng ảnh ít, giúp tăng số lần xuất hiện của chúng trong quá trình huấn luyện mà không cần thực hiện sao chép dữ liệu thủ công.

3.2. Khung nghiên cứu đề xuất



Hình 3.2. Sơ đồ quy trình hoạt động của hệ thống nhận dạng rắn của nghiên cứu

3.3. Mô hình cơ sở

Mô hình Machine Learning XGBoost được dùng làm mô hình cơ sở cho bài toán phân loại cấp 1 giữa cá thể rắn thuộc nhóm “Có độc” (label =1) và “Không độc”(label =0). Mục tiêu mô hình không chỉ cung cấp một chuẩn tham chiếu để đánh giá hiệu quả của các kiến trúc học sâu ở các giai đoạn tiếp theo, mà còn giúp làm rõ mức độ đóng góp của các đặc trưng thị giác cơ bản đối với nhiệm vụ nhận dạng độc tính của rắn.

Quy trình xử lý bắt đầu từ việc chuẩn hóa toàn bộ ảnh đầu vào về cùng kích thước 224×224 pixel nhằm đảm bảo tính nhất quán trong quá trình trích xuất đặc trưng. Đối với đặc trưng hình thái, ảnh màu sẽ được chuyển sang ảnh xám và áp dụng kỹ thuật Contrast Limited Adaptive Histogram Equalization (CLAHE) nhằm tăng cường độ tương phản cục bộ, giúp làm nổi bật các chi tiết về hoa văn, hình dạng vảy và cấu trúc cơ thể của rắn trong những điều kiện chiếu sáng khác nhau. Bước xử lý này góp phần giảm ảnh hưởng của nhiễu môi trường và cải thiện khả năng biểu diễn đặc trưng của dữ liệu. Trên ảnh đã được tăng cường chất lượng, nghiên cứu sử dụng Histogram of Oriented Gradients (HOG) để trích xuất các đặc trưng hình học. HOG

mô tả sự phân bố hướng gradient của các điểm ảnh, nắm bắt hiệu quả các đặc điểm liên quan đến đường viền, hình dạng đầu, thân và hoa văn đặc trưng của từng nhóm rắn. Bên cạnh đó, thông tin màu sắc được biểu diễn thông qua lược đồ màu trong không gian màu HSV, với khả năng tách biệt thành phần sắc độ với độ sáng, giúp mô hình khai thác tốt hơn sự khác biệt về màu sắc giữa các loài trong điều kiện ánh sáng thay đổi. Hai nhóm đặc trưng này sau đó được kết hợp thành một vector đặc trưng thống nhất đại diện cho mỗi ảnh. Sau quá trình chuẩn bị dữ liệu ban đầu, tập mẫu được chia thành ba tập train - validation - test theo tỷ lệ 70% - 15% - 15% nhằm tối ưu hóa khả năng tổng quát và ngăn chặn hiện tượng quá khớp. Tập huấn luyện được sử dụng để xây dựng mô hình, tập xác thực được dùng để theo dõi hàm mất mát (logloss) qua từng chu kỳ để đưa ra quyết định dừng học sớm khi cần thiết, trong khi tập kiểm tra còn lại được giữ cách ly hoàn toàn nhằm đóng vai trò là dữ liệu thực tế nhằm đánh giá khách quan hiệu suất của mô hình.

Trong giai đoạn huấn luyện, kiến trúc XGBoost được cấu hình để tối ưu hóa hàm mục tiêu phân phối logistic (binary:logistic), tuân thủ chặt chẽ bản chất của toán phân loại nhị phân. Các siêu tham số như tốc độ học ở mức 0.05, 300 cây quyết định và độ sâu giới hạn bằng 6 được thiết lập nhằm cân bằng giữa năng lực giải quyết các điểm dữ liệu phi tuyến tính phức tạp và rủi ro học vẹt. Về cơ chế đánh giá hiệu năng, thay vì chỉ chú trọng vào độ chính xác tổng thể (Accuracy), hệ thống phân tích logic điều hướng trọng tâm vào Ma trận nhầm lẫn và tối ưu hóa chỉ số Recall đối với lớp "Có độc". Thiết lập này bắt nguồn từ yêu cầu an toàn thực tiễn của bài toán khi hệ thống cần phải ưu tiên tối đa hóa khả năng bắt đúng các trường hợp rắn có độc nhằm triệt tiêu dự đoán nhầm rắn độc thành không độc, bởi vì sai số mang ý nghĩa nguy hiểm đến tính mạng, quan trọng hơn so với việc nhận diện nhầm một loài rắn lành tính.

3.4. Mô hình học phân cấp (Hướng 1)

Mô hình học phân cấp (Hướng 1) tiếp cận bài toán phân loại theo hai mức quyết định liên tiếp (i) xác định trạng thái độc tính của rắn và (ii) nhận diện họ rắn trong phạm vi nhóm độc hoặc không độc đã được xác định ở bước trước. Hệ thống bao gồm ba mô hình huấn luyện độc lập là Model A (phân loại rắn có độc hay không), Model B (từ nhóm có độc tiếp tục phân loại ra họ rắn) và Model C (từ nhóm không độc phân loại ra các họ rắn không độc), xây dựng dựa trên cùng backbone Vision Transformer (ViT) tiền huấn luyện nhưng được tối ưu cho các nhiệm vụ khác nhau. Để thiết lập dữ liệu huấn luyện tương thích cho cấu trúc phân cấp từ tập dữ liệu gốc gồm 4.153 ảnh, nhãn được cấu trúc lại một cách chặt chẽ, nhãn `label_doc` quy ước bằng 1 cho trạng thái có độc và nhãn 0 cho không độc dành riêng cho Model A. Đối với nhãn họ (`label_ho`), do hiện tượng trùng lặp phân loại học khi hai họ Rắn biển Hydrophiidae và Rắn nước Colubridae tồn tại đồng thời cả loài có độc lẫn loài không độc, nghiên cứu tiến hành mở rộng không gian nhãn gốc từ 7 thành 9 lớp bằng cách gắn thêm hậu tố độc tính. Từ tổ hợp 9 lớp này, dữ liệu tiếp tục được lọc và mã hóa lại thành các dải nhãn liên tục với 5 lớp rắn độc với nhãn `label_ho_b` dùng cho Model B và tập 4 lớp rắn không độc với nhãn `label_ho_c` dùng cho Model C.

Việc tách hệ thống thành hai Model B và Model C xuất phát từ yêu cầu cô lập nhiều đặc trưng và triệt tiêu mâu thuẫn ngữ nghĩa trong không gian nhãn, đặc biệt là đối với các họ rắn có sự chồng lấn về độc tính. Nếu gộp chung toàn bộ 9 lớp vào một mô hình phẳng duy nhất, mạng nơ-ron sẽ buộc phải học đồng thời cả ranh giới độc tố lẫn ranh giới hình thái phân loại học trên cùng một không gian biểu diễn, dễ gây xung đột thông tin và suy giảm hiệu năng. Do đó, Model

A được đặt ở Cấp 1 để giải quyết bài toán phân loại nhị phân, tập trung trích xuất các đặc trưng thị giác tổng quát liên quan đến độc tính qua hàm kích hoạt Sigmoid và hàm mất mát BCEWithLogitsLoss. Khi luồng dữ liệu được phân nhánh sang Cấp 2, Model B và Model C hoạt động như hai chuyên gia độc lập sử dụng hàm mất mát CrossEntropyLoss, chịu trách nhiệm tối ưu hóa phân phối để định danh chính xác các họ rắn độc và nhóm không độc. Giải pháp này giúp thu hẹp đáng kể không gian tìm kiếm đặc trưng của từng mô hình, thúc đẩy tiến trình hội tụ nhanh hơn và giảm thiểu tối đa rủi ro nhận diện sai lệch giữa hai

Trong giai đoạn suy luận, hệ thống trích xuất đồng thời các phân phối xác suất từ cả ba mô hình thành phần (`prob_doc`, `prob_b`, `prob_c`) thay vì phân nhánh cơ học. Dựa trên các đại lượng này, quá trình tích hợp kết quả để đưa ra dự đoán cuối cùng trên 9 lớp gốc được thực nghiệm thông qua hai cơ chế: chốt cứng và trọng số mềm. Cơ chế chốt cứng sử dụng ngưỡng quyết định cố định 0.5 đối với `prob_doc` để phân nhánh dữ liệu. Nếu `prob_doc > 0.5`, ảnh được chuyển sang nhóm có độc và nhãn họ dự đoán được lấy hoàn toàn từ lớp có xác suất cao nhất của Model B, ngược lại, nhãn họ được trích xuất từ xác suất cao nhất Model C. Mặc dù cơ chế có cấu trúc đơn giản và dễ triển khai nhưng kết quả phân loại cuối cùng phụ thuộc hoàn toàn vào quyết định nhị phân của Model A. Khi Model A đưa ra dự đoán sai, đặc biệt đối với các mẫu nằm gần ngưỡng quyết định, toàn bộ phần thông tin từ mô hình còn lại bị loại bỏ, kéo theo sai số bị lan truyền và khuếch đại sang tầng thứ hai. Nhằm khắc phục hạn chế này, cơ chế trọng số mềm (softmax weight) sử dụng trực tiếp xác suất liên tục của Model A làm hệ số pha trộn hai phân phối thành phần thành một vector tích hợp đầy đủ trên 9 lớp. Theo đó, xác suất cuối cùng của các lớp độc được tính bằng `prob_doc * prob_b` và các lớp không độc được tính bằng `(1 - prob_doc) * prob_c`. Nhãn dự đoán cuối cùng là vị trí có xác suất tổng hợp cao nhất, cho phép cả hai mô hình cùng đóng góp thông tin với trọng số biến thiên liên tục, qua đó tối ưu hóa quyết định tại các vùng dữ liệu có độ bất định cao.

3.5. Mô hình học đa nhiệm (Hướng 2)

Khác với Hướng 1, bài toán được phân rã thành ba mô hình độc lập theo cấu trúc phân cấp, Hướng 2 tiếp cận theo hướng học đa nhiệm (*multi-task learning*), đồng thời thực hiện hai nhiệm vụ nhận diện độc tính và phân loại họ rắn trong một kiến trúc thống nhất. Cách tiếp cận này dựa trên giả định hai nhiệm vụ tồn tại mối liên hệ về mặt sinh học, khi nhiều họ rắn có xu hướng gắn với trạng thái độc với tính đặc trưng. Do đó, việc chia sẻ biểu diễn đặc trưng giữa các nhiệm vụ có thể giúp mô hình khai thác tốt hơn các tín hiệu chung, tăng khả năng khái quát hóa và giảm hiện tượng học dư thừa giữa các mô hình. Bên cạnh đó, việc sử dụng một backbone duy nhất cũng giúp giảm đáng kể số lượng tham số và chi phí lưu trữ.

Mô hình được xây dựng trên nền tảng Vision Transformer (ViT) tiền huấn luyện, trong đó toàn bộ ảnh đầu vào được xử lý thông qua một backbone dùng chung để học biểu diễn đặc trưng thị giác. Đối với mỗi ảnh đầu vào, token [CLS] ở lớp ẩn cuối cùng của backbone ViT được sử dụng để biểu diễn tổng quát của toàn bộ ảnh. Biểu diễn này được truyền song song tới hai nhánh phân loại độc lập về tham số. Nhánh thứ nhất, ký hiệu là *head_doc*, thực hiện nhiệm vụ phân loại nhị phân nhằm xác định trạng thái độc hoặc không độc của cá thể rắn. Nhánh thứ hai, *head_ho*, thực hiện nhiệm vụ phân loại đa lớp trên không gian gồm chín họ rắn. Nhờ sử dụng chung một backbone, các đặc trưng thị giác được học từ nhiệm vụ này có thể hỗ trợ nhiệm vụ còn lại, qua đó nâng cao khả năng khái quát hóa của mô hình.

Do hai head cùng chia sẻ một backbone ViT, quá trình huấn luyện được tối ưu thông qua một hàm mất mát đa nhiệm thống nhất, cho phép gradient từ cả hai nhiệm vụ đồng thời cập nhật không gian biểu diễn đặc trưng dùng chung. Hàm mất mát tổng được xác định dưới dạng:

$$L = \lambda_{doc} \times L_{doc} + \lambda_{ho} \times L_{ho}$$

trong đó L_{doc} và L_{ho} là mất mát của head_doc và head_ho của nhiệm vụ phân loại độc tính và phân loại họ rắn tính trên cùng một batch ảnh, còn λ_{doc} và λ_{ho} là các hệ số điều chỉnh mức độ đóng góp của từng nhiệm vụ vào tổng gradient. Trong nghiên cứu này, $\lambda_{doc} = 1,0$ và $\lambda_{ho} = 0,5$, nhằm ưu tiên tối ưu hóa nhiệm vụ nhận diện độc tính, đồng thời vẫn duy trì tín hiệu giám sát từ nhiệm vụ phân loại họ rắn để hỗ trợ quá trình học biểu diễn chung. Đối với nhánh phân loại độc tính L_{doc} , hàm BCEWithLogitsLoss được sử dụng cùng hệ số pos_weight nhằm bù đắp sự mất cân bằng giữa hai lớp và tăng khả năng nhận diện các trường hợp rắn độc. Đối với nhánh phân loại họ rắn L_{ho} , hàm CrossEntropyLoss được kết hợp với trọng số lớp tính theo nghịch đảo tần suất xuất hiện của từng họ rắn, giúp giảm xu hướng thiên lệch về các lớp chiếm ưu thế trong dữ liệu. Hai cơ chế cân bằng này được thiết kế riêng cho từng nhiệm vụ trước khi được tổng hợp thành một giá trị mất mát duy nhất để thực hiện lan truyền ngược và cập nhật tham số của toàn bộ mạng.

Quá trình huấn luyện được triển khai theo chiến lược fine-tuning nhiều giai đoạn nhằm cân bằng giữa khả năng thích nghi với dữ liệu chuyên biệt. Ở giai đoạn đầu, backbone ViT được đóng băng hoàn toàn và chỉ hai head được cập nhật tham số, giúp các nhánh đầu ra nhanh chóng học được ranh giới quyết định đặc thù của từng nhiệm vụ mà không làm biến đổi không gian biểu diễn chung. Tiếp theo, toàn bộ mạng được mở khóa để thực hiện fine-tuning với tốc độ học phân tầng, trong đó backbone được cập nhật thận trọng hơn so với các lớp phân loại nhằm duy trì tính ổn định của các đặc trưng đã học. Cuối cùng, mô hình tiếp tục được tinh chỉnh từ checkpoint tốt nhất với tốc độ học thấp hơn, cho phép tối ưu các tham số cục bộ và cải thiện khả năng hội tụ mà không làm phá vỡ nghiệm đã hình thành ở các giai đoạn trước.

Trong quá trình thực hiện, mô hình chỉ cần một lần lan truyền xuôi để tạo ra đồng thời hai kết quả dự đoán. Đầu ra từ head_doc được chuyển thành xác suất độc tính thông qua hàm sigmoid, trong khi đầu ra từ head_ho được chuyển thành phân phối xác suất trên chín họ rắn bằng hàm softmax. Nhờ cơ chế dự đoán song song này, SnakeViT có khả năng cung cấp đồng thời thông tin về mức độ nguy hiểm và danh tính phân loại của cá thể rắn trong một kiến trúc thống nhất, góp phần nâng cao hiệu quả nhận diện và giảm chi phí tính toán của hệ thống.

3.6. Mô hình kết hợp

Sau khi triển khai độc lập kiến trúc phân cấp (Hướng 1) và học đa nhiệm (Hướng 2), nghiên cứu đề xuất Mô hình kết hợp nhằm khai thác tối đa thế mạnh chuyên biệt của từng phương pháp. Trong mô hình này, cấu trúc đa nhiệm của Hướng 2 được phân công đảm nhận vai trò rẽ nhánh tại Cấp 1 (phân loại nhị phân độc/không độc), tận dụng năng lực trích xuất biểu diễn đặc trưng phong phú nhờ quá trình tối ưu hóa đồng thời trên nhiều nhiệm vụ. Ngược lại, nhiệm vụ định danh chi tiết họ loài tại Cấp 2 được giao cho Model B và Model C từ Hướng 1, nhờ được huấn luyện chuyên sâu trên các không gian nhãn đã được thu hẹp (5 họ độc và 4 họ không độc), hai mô hình chuyên gia này sở hữu khả năng phân loại cục bộ chính xác hơn so với đầu ra đa lớp tuyến tính của Hướng 2.

Trước khi thực hiện huấn luyện mô hình, quy trình chuẩn bị hệ thống bắt đầu bằng việc nạp đồng thời ba mô hình thành phần (`model_h2`, `modelB`, `modelC`) từ các điểm kiểm tra (checkpoint) đạt hiệu năng tối ưu nhất. Cụ thể, mạng đa nhiệm (`model_h2`) cùng hai mạng chuyên gia (`modelB` và `modelC`) được chuyển đổi thống nhất sang chế độ đánh giá để vô hiệu hóa Dropout, để đảm bảo tính xác định tuyệt đối của kết quả đầu ra. Song song đó, các bộ từ điển ánh xạ nghịch đảo (`b2ho` và `c2ho`) được tái sử dụng nguyên vẹn nhằm bảo toàn quy tắc chiếu hệ tọa độ, giúp quy đổi chuẩn xác các chỉ số nhãn nội bộ của hai mô hình chuyên gia về không gian 9 lớp gốc của toàn hệ thống. Tiếp theo nghiên cứu tiến hành xác lập ngưỡng quyết định (threshold) tối ưu cho Cấp 1 thông qua tập validation, thay vì áp đặt một giá trị mặc định. Bằng cách thiết lập đường cong Precision-Recall từ vector xác suất của mạng đa nhiệm, nghiên cứu tiến hành rà soát có hệ thống để tìm kiếm điểm cắt thỏa mãn điều kiện y tế thực tiễn, với mục đích tối đa hóa độ nhạy nhận diện rắn độc trong khi vẫn duy trì độ chuẩn xác tối thiểu ở mức 0.70, đã trích xuất được ngưỡng tối ưu là 0.051. Giá trị này kết hợp cùng ngưỡng trung tính 0.5, tạo thành hai kịch bản kiểm thử độc lập (Hybrid-0.051 và Hybrid-0.5), cung cấp cơ sở quan trọng để đánh giá đa chiều hiệu năng định tuyến của toàn hệ thống.

Trong giai đoạn huấn luyện, dữ liệu đầu vào được xử lý đồng thời qua cả ba mô hình thành phần nhằm tối ưu hóa luồng tính toán. Cụ thể, cùng một tensor ảnh đầu vào được đưa vào `model_h2` để lấy `logit_doc`, riêng đầu ra `head_ho` bị loại bỏ hoàn toàn vì nhiệm vụ phân loại họ ở Lớp 2 đã được giao cho Model B và C. Đồng thời tensor ảnh đó cũng được đưa qua `modelB` để lấy vector logit 5 chiều có độc (`out_b`) và qua `modelC` để lấy vector logit 4 chiều không độc (`out_c`). Hàm sigmoid được áp dụng để thu được xác suất `prob_doc` $\in (0,1)$ cho từng ảnh, sau đó so sánh với ngưỡng (THRESHOLD) để ra nhãn nhị phân `pred_doc` (1 nếu `prob_doc` $\geq$ THRESHOLD, 0 nếu ngược lại). Cơ chế Lớp 2 được hoạt động theo nguyên tắc chốt cứng, với những ảnh được dự đoán là rắn độc, chỉ số họ dự đoán cuối cùng được lấy từ argmax của `out_b`, tức là lớp có điểm logit cao nhất trong không gian 5 họ độc, sau đó quy đổi về chỉ số gốc thông qua từ điển `b2ho`. Ngược lại, với những ảnh được dự đoán là rắn không độc, chỉ số họ được lấy từ argmax của `out_c`, lớp có logit cao nhất trong 4 họ không độc và quy đổi ngược qua `c2ho`. Kết quả là mỗi ảnh nhận được đồng thời hai nhãn dự đoán từ Lớp 1 và từ Lớp 2.

Mô hình kết hợp được đánh giá theo hai trường hợp ngưỡng khác nhau trên cùng một cơ chế kiến trúc và cùng tập kiểm tra, nhằm phân tách rõ ảnh hưởng của lựa chọn ngưỡng lên từng khía cạnh hiệu năng. Trường hợp thứ nhất sử dụng ngưỡng 0,051, ngưỡng tối ưu được tìm trên tập validation theo nguyên tắc ưu tiên recall. Ở ngưỡng này, xác suất `prob_doc` chỉ cần vượt qua một mức thấp để ảnh được định tuyến sang nhánh "có độc", dẫn đến tỉ lệ lớn ảnh được đẩy sang Model B để phân loại họ độc, chỉ những ảnh mà `model_h2` chắc chắn không độc mới được chuyển sang Model C. Hệ quả là recall của lớp độc ở Lớp 1 tăng cao, nhưng precision giảm do nhiều ảnh không độc bị định tuyến nhầm sang nhánh B, dễ dẫn đến sai lệch ở đầu ra phân loại họ. Trường hợp thứ hai sử dụng ngưỡng 0,5, tương đương với việc chọn nhãn có xác suất cao hơn 50% làm dự đoán. Ở ngưỡng này, tỉ lệ ảnh được định tuyến sang hai nhánh B và C cân bằng hơn, precision và recall của Lớp 1 được phân phối đều hơn giữa hai lớp, dẫn đến một kết quả tổng thể ổn định hơn nhưng không tối ưu riêng cho lớp độc. Việc chạy song song cả hai trường hợp và so sánh kết quả cho phép đánh giá trực tiếp đánh đổi giữa hai chiến lược ngưỡng trong cùng một kiến trúc kết hợp.

CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU

4.1. Kết quả mô hình cơ sở


Sau khi hoàn tất quá trình huấn luyện, mô hình cơ sở được đánh giá trên tập kiểm tra độc lập gồm 627 ảnh với sự phân bố khá cân bằng với 315 ảnh thuộc lớp "Không độc" và 312 ảnh thuộc lớp "Có độc", đảm bảo tính khách quan cho các chỉ số đo lường mà không bị ảnh hưởng do hiện tượng mất cân bằng lớp gây ra. Kết quả thực nghiệm ghi nhận mức độ chính xác tổng thể (Accuracy) của mô hình đạt 59%, phản ánh việc số hóa cấu trúc hình học kết hợp phân bố sắc tố thủ công tuy cung cấp được thông tin phân biệt cơ bản, nhưng vẫn đối mặt với thách thức lớn trong việc thiết lập một ranh giới phân lớp rõ ràng giữa hai nhóm có độc và không độc.

--- BÁO CÁO KẾT QUẢ PHÂN LOẠI TRÊN TẬP TEST ---				
	precision	recall	f1-score	support
Không độc (0)	0.60	0.58	0.59	315
Có độc (1)	0.59	0.61	0.60	312
accuracy			0.59	627
macro avg	0.59	0.59	0.59	627
weighted avg	0.59	0.59	0.59	627

Hình 4.1a. Kết quả các chỉ số đánh giá hiệu suất mô hình phân loại rắn độc XGBoost

Đối với lớp "Có độc", mô hình Machine learning chỉ đạt Recall ở mức 61%, đồng nghĩa hệ thống đã bỏ sót tới 39% cá thể rắn độc và nhận diện sai chúng thành rắn lành tính. Mặc dù bộ lọc HOG có thể số hóa cấu trúc mép vảy hay hình dáng đầu rắn trong điều kiện lý tưởng, nhưng kém bền vững trước các biến đổi phi tuyến tính của ảnh thực tế như tư thế cuộn tròn, góc chụp khuất hoặc sự che lấp từ thực vật đã làm biến dạng các đường biên hình học cơ bản, khiến mô hình thất bại trong việc thu thập các dấu hiệu cảnh báo độc tính. Ngược lại, chỉ số Recall của lớp "Không độc" cũng chỉ dừng ở mức 58%, tức có 42% cá thể rắn không độc bị nhận dạng nhầm thành rắn độc.

Ma trận nhầm lẫn một lần nữa cho thấy sự phân bố lỗi khá đồng đều trong cơ cấu dự đoán của thuật toán. Cụ thể, hệ thống chỉ phân loại chính xác được 189 cá thể rắn độc và 183 cá thể lành tính. Đối với 255 trường hợp dự đoán sai, mô hình ghi nhận 123 lỗi bỏ sót rắn độc và 132 trường hợp nhận diện nhầm rắn lành. Sự cân bằng tương đối giữa hai loại sai lầm này khẳng định rằng bản thân thuật toán XGBoost không bị thiên lệch về bất kỳ lớp cụ thể nào. Thay vào đó, kết quả này củng cố thêm nhận định rằng bộ đặc trưng cơ sở đã đạt đến ngưỡng bão hòa, chúng đủ để duy trì một điểm chuẩn dự đoán trung lập nhưng hoàn toàn thiếu đi chiều sâu thông tin biểu diễn cần thiết để tạo ra một mặt phẳng siêu phân cách dứt khoát nhằm phân tách triệt để hai nhóm.



Hình 4.1b. Ma trận nhầm lẫn dự báo rắn độc - không độc của mô hình XGBoost

Kết quả cho thấy mặc dù sự kết hợp giữa CLAHE, HOG, HSV Histogram và XGBoost có thể khai thác được một phần thông tin về hình dạng và màu sắc của rắn, nhưng các đặc trưng chưa đủ khả năng biểu diễn những khác biệt phức tạp giữa các loài có độc và không độc trong điều kiện dữ liệu thực tế. Nhiều đặc điểm quan trọng như cấu trúc vảy, hoa văn cục bộ hoặc mối quan hệ không gian giữa các bộ phận cơ thể khó được mô tả đầy đủ thông qua các đặc trưng truyền thống. Do đó, mô hình cơ sở đóng vai trò là đường chuẩn tham chiếu, đồng thời cho thấy sự cần thiết của các phương pháp học sâu có khả năng tự động học đặc trưng ở mức ngữ nghĩa cao hơn trong các giai đoạn nghiên cứu tiếp theo.

4.2. Kết quả mô hình phân tầng

Hiệu năng của hệ thống học phân cấp trên tập kiểm tra gồm 623 mẫu được bắt đầu bằng việc phân tích khả năng phân loại nhị phân của Model A ở cấp thứ nhất. Với ngưỡng quyết định 0,5, mô hình đạt độ chính xác tổng thể 84% và chỉ số AUC-ROC 0,9124, cho thấy khả năng phân biệt tốt giữa hai nhóm rắn độc và không độc. Đáng chú ý, mô hình đạt độ nhạy khá cao (recall= 0,87) đối với lớp rắn độc, nhận diện đúng 87% các trường hợp có độc trong tập kiểm tra. Kết quả có ý nghĩa thực tiễn quan trọng trong bối cảnh ý tế và sơ cứu, bởi sai sót trong việc phân loại rắn độc thành không độc có thể dẫn đến những hậu quả nghiêm trọng hơn so với chiều ngược lại. Mức recall cao cho thấy Model A có khả năng phát hiện hiệu quả các trường hợp tiềm ẩn nguy cơ, qua đó giảm thiểu số lượng mẫu rắn độc bị bỏ sót ở giai đoạn phân loại ban đầu. Kết quả này khẳng định vai trò của Model A như một tầng sàng lọc đáng tin cậy, tạo tiền đề cho quá trình phân loại chuyên sâu ở các cấp tiếp theo của hệ thống.

[Lớp 1 - Model A] threshold=0.5					
	precision	recall	f1-score	support	
Không độc	0.86	0.82	0.84	311	
Độc	0.83	0.87	0.85	312	
accuracy			0.84	623	
macro avg	0.84	0.84	0.84	623	
weighted avg	0.84	0.84	0.84	623	
AUC-ROC: 0.9124					

Hình 4.2a. Kết quả các chỉ số đánh giá hiệu suất cấp 1 mô hình phân cấp ViT hướng 1

Dựa trên kết quả Cấp 1, cơ chế chốt cứng tại Cấp 2 đạt độ chính xác tổng thể 78%. Thông qua ma trận nhầm lẫn, sự sụt giảm độ chính xác có nguyên nhân cốt lõi từ hiện tượng lan truyền sai số một chiều, khi Model A phân nhánh sai, mô hình chuyên gia ở tầng dưới hoàn toàn mất đi cơ hội hiệu chỉnh. Cụ thể, có đến 18 mẫu Rắn nước không độc (Colubridae_khongdoc) bị đẩy nhầm sang luồng có độc và ép buộc phải phân loại thành Họ rắn lục (Viperidae) hay 24 mẫu khác bị ép thành Rắn hổ (Elapidae). Hậu quả là chỉ số recall của các lớp ở Cấp 2 bị kéo tụt do hiện tượng "chỉ định thầu" sai từ đầu. Việc thiết lập một ranh giới rõ nhánh cứng nhắc khiến hệ thống trở nên nhạy cảm và dễ tổn thương trước những mẫu ảnh có đặc trưng nguy trang hoặc nằm ở vùng ranh giới bất định giữa độc và không độc.

Nhằm khắc phục điểm nghẽn của việc ép luồng dữ liệu, cơ chế trọng số mềm (softmax weight) sử dụng trực tiếp xác suất liên tục của Model A để dung hòa góc nhìn từ cả hai mô hình chuyên gia, qua đó nâng độ chính xác tổng thể lên 80%. Cơ chế này giúp phục hồi đáng kể chỉ số recall cho các họ rắn trọng yếu như recall của họ Viperidae tăng từ 0.83 lên 0.85, họ Elapidae tăng từ 0.82 lên 0.85, và họ Rắn nước có độc (Colubridae_doc) tăng từ 0.77 lên 0.80. Về mặt bản chất, thay vì khóa chặt luồng xử lý tại vùng bất định, trọng số mềm cho phép hệ thống lắng nghe ý kiến của cả hai nhánh. Nếu Model C ở nhánh không độc nhận diện cực kỳ tự tin về một đặc điểm hình thái quen thuộc, nó có đủ trọng lượng để lật ngược lại phán quyết chệnh vênh của Model A.

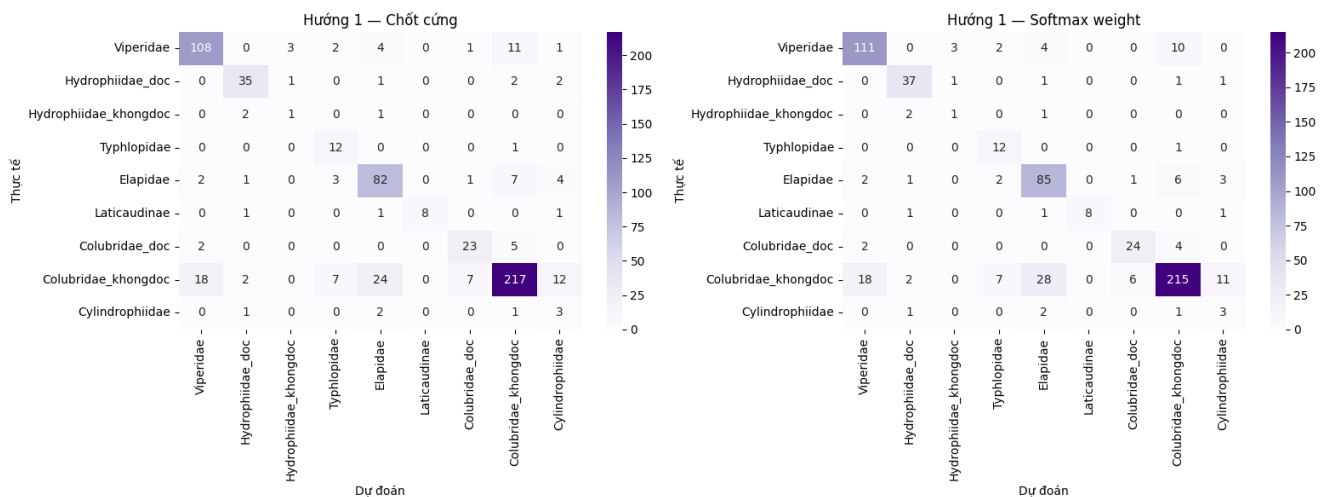
[Lớp 2 - Chốt cứng]

	precision	recall	f1-score	support
Họ rắn lục Viperidae	0.83	0.83	0.83	130
Rắn biển Hydrophiidae_doc	0.83	0.85	0.84	41
Rắn biển Hydrophiidae_khongdoc	0.20	0.25	0.22	4
Rắn giun Typhlopidae	0.50	0.92	0.65	13
Rắn hổ Elapidae	0.71	0.82	0.76	100
Rắn hổ biển Laticaudinae	1.00	0.73	0.84	11
Rắn nước Colubridae_doc	0.72	0.77	0.74	30
Rắn nước Colubridae_khongdoc	0.89	0.76	0.82	287
Rắn trun Cylindrophiiidae	0.13	0.43	0.20	7
accuracy			0.78	623
macro avg	0.65	0.71	0.66	623
weighted avg	0.82	0.78	0.80	623

[Lớp 2 - Softmax weight]

	precision	recall	f1-score	support
Họ rắn lục Viperidae	0.83	0.85	0.84	130
Rắn biển Hydrophiidae_doc	0.84	0.90	0.87	41
Rắn biển Hydrophiidae_khongdoc	0.20	0.25	0.22	4
Rắn giun Typhlopidae	0.52	0.92	0.67	13
Rắn hổ Elapidae	0.70	0.85	0.77	100
Rắn hổ biển Laticaudinae	1.00	0.73	0.84	11
Rắn nước Colubridae_doc	0.77	0.80	0.79	30
Rắn nước Colubridae_khongdoc	0.90	0.75	0.82	287
Rắn trun Cylindrophiiidae	0.16	0.43	0.23	7
accuracy			0.80	623
macro avg	0.66	0.72	0.67	623
weighted avg	0.83	0.80	0.80	623

Hình 4.2b. Kết quả chỉ số đánh giá hiệu suất Cấp 2 mô hình phân cấp ViT hướng 1 theo cơ chế chốt cứng và chốt mềm



Hình 4.2c. Ma trận nhầm lẫn dự báo Cấp 2 mô hình phân cấp ViT hướng 1 theo cơ chế chốt cứng và chốt mềm

Mặc dù cơ chế trọng số mềm mang lại hiệu năng nhận diện nhỉnh hơn 2%, nghiên cứu vẫn quyết định chọn cơ chế chốt cứng làm kiến trúc nền tảng để phát triển và cải tiến cho các

mô hình phía sau nhờ những giá trị cốt lõi về mặt vận hành và thiết kế hệ thống. Lý do nằm ở khả năng tối ưu hóa tài nguyên tính toán, việc chốt cứng mức xác suất giúp hệ thống chỉ cần kích hoạt duy nhất một mạng nơ-ron ở tầng thứ hai thay vì phải xử lý song song cả ba mô hình đồ sộ, đáp ứng tốt yêu cầu độ trễ thấp khi triển khai trên các thiết bị sơ cứu di động. Bên cạnh đó, sự phân tách dứt khoát ranh giới 5 họ độc và 4 họ không độc cho phép nhà phát triển dễ dàng tái huấn luyện hoặc thay thế một mạng chuyên gia bất kỳ mà không làm xáo trộn cấu trúc không gian nhãn của toàn hệ thống. Logic của cơ chế chốt cứng phù hợp hơn với tư duy lâm sàng, ưu tiên xác định tính chất độc tính trước khi đi sâu vào định danh sinh học của cá thể, chỉ hiệu quả về mặt thuật toán mà còn minh bạch và dễ diễn giải trong thực tiễn ứng dụng.

4.3. So sánh kết quả phân tầng giữa mô hình cơ sở và mô hình phân cấp

Trong bước tiền xử lý, nhánh Machine Learning sử dụng thư viện OpenCV (cv2) để chuyển đổi ảnh xám và cân bằng histogram, thư viện này rất nhạy cảm với các file ảnh bị hỏng header hoặc sai đuôi mở rộng (ví dụ ảnh lưu .jpg nhưng thực chất là .webp hoặc .jfif), dẫn đến xử lý được 4118 ảnh. Trong khi đó, nhánh Deep Learning sử dụng thư viện PIL kết hợp với torchvision.transforms, có khả năng chịu lỗi tốt hơn, tự động ép kiểu và giữ lại được toàn bộ 4.153 ảnh gốc. Sự chênh lệch 35 ảnh (tương đương 0.8%) là rất nhỏ và không làm thay đổi phân phối tổng thể của hai tập dữ liệu.

Để đánh giá toàn diện hiệu quả của phương pháp phân cấp, nghiên cứu tiến hành đối sánh hiệu năng giữa mô hình cơ sở thuộc nhóm học máy truyền thống (XGBoost) và mô hình học sâu (ViT) tại điểm rẽ nhánh trọng yếu của Cấp 1. Kết quả thực nghiệm chỉ ra sự chênh lệch nền tảng về năng lực phân loại nhị phân (có độc/không độc) giữa hai phương pháp tiếp cận. Trong khi mô hình XGBoost bộc lộ rõ những giới hạn khi dự đoán trên tập dữ liệu hình ảnh thực tế, dẫn đến các chỉ số định lượng như độ chính xác tổng thể và độ nhạy không đạt ngưỡng an toàn kỳ vọng, thì mô hình ViT ở Hướng 1 lại thể hiện sự vượt trội toàn diện với accuracy khoảng 84%. Cụ thể, ViT đã thiết lập được một hàng rào quyết định vững chắc, khoanh vùng chính xác nhóm rắn có độc với tỷ lệ nhận diện đúng rất cao, khắc phục hiệu quả tình trạng phân loại sai lệch và bỏ lọt rắn độc thường xuyên xuất hiện trên mô hình cơ sở XGBoost. Sự chênh lệch này trực tiếp quyết định đến chất lượng của toàn bộ hệ thống phân cấp, bởi một luồng định tuyến sai lầm ở Cấp 1 sẽ kéo theo hiệu ứng lan truyền sai số không thể vãn hồi ở các tầng định danh chuyên sâu phía sau.

Bảng 4.3. Tổng hợp kết quả phân loại mô hình XGBoost và mô hình Vit

	Mô hình cơ sở XGBoost			Mô hình phân cấp Vit		
	Precision	Recall	F1-score	Precision	Recall	F1-score
Không độc	0.60	0.58	0.59	0.86	0.82	0.84
Có độc	0.59	0.61	0.60	0.83	0.87	0.85
Accuracy	0.59			0.84		

Sự cách biệt về hiệu năng vận hành có thể bắt nguồn từ bản chất kiến trúc và phương thức trích xuất đặc trưng của từng mô hình, qua đó làm nổi bật luận điểm cốt lõi trong việc định hướng lựa chọn các mô hình Deep Learning cho bài toán thị giác máy tính. Đối với các thuật toán Machine Learning như XGBoost, quá trình phân loại phụ thuộc khắt khe vào các đặc trưng được trích xuất thủ công hoặc các vector điểm ảnh bị làm phẳng, dẫn đến sự triệt tiêu hoàn toàn thông tin không gian hai chiều và cấu trúc liên kết cục bộ của hình ảnh. Ngược lại, mạng nơ-ron học sâu ViT với cơ chế tự chú ý sở hữu khả năng tự động khai phá và ánh xạ các biểu diễn không gian phức tạp trực tiếp từ ma trận điểm ảnh thô. Kiến trúc này cho phép ViT không chỉ nắm bắt được các chi tiết hình thái vi mô như cấu trúc vảy, hình dạng đầu hay hoa văn, mà còn phân tích được mối tương quan toàn cục của chủ thể bất chấp sự nhiễu loạn về bối cảnh tự nhiên, góc chụp hay điều kiện chiếu sáng. Do đó, sự vượt trội của kiến trúc học sâu so với phương pháp học máy truyền thống không chỉ dừng lại ở việc gia tăng chỉ số đo lường, mà cốt lõi là năng lực giải quyết triệt để bài toán biểu diễn dữ liệu phi cấu trúc. Kết quả đối sánh đã cung cấp luận cứ vững chắc, khẳng định Deep Learning là nền tảng tối ưu nhằm đáp ứng trọn vẹn những yêu cầu khắt khe về độ tin cậy và khả năng tổng quát hóa trong phân loại sinh học.

4.4. Kết quả mô hình học đa nhiệm

Mô hình học đa nhiệm sử dụng Vision Transformer được đánh giá trên tập kiểm tra gồm 623 ảnh, đồng thời thực hiện hai nhiệm vụ là phân loại độc tính (Có độc/Không độc) và phân loại họ rắn. Đối với nhiệm vụ phân loại độc tính, kết quả cho thấy mô hình tại ngưỡng 0.5, đạt độ chính xác tổng thể 86%, cùng giá trị Precision, Recall và F1-score đều đạt 0,86 ở mức khá. Một mức hiệu năng tương đối cao đối với bài toán nhận dạng sinh vật ngoài tự nhiên, nơi chất lượng ảnh thường không đồng nhất và tồn tại nhiều yếu tố gây nhiễu như góc chụp, điều kiện ánh sáng và sự che khuất của môi trường.

TEST SET - Hướng 2 (best checkpoint epoch 13)				
=====				
[Lớp 1 - Độc/Không độc] threshold=0.5				
	precision	recall	f1-score	support
Không độc	0.87	0.85	0.86	311
Độc	0.85	0.87	0.86	312
accuracy			0.86	623
macro avg	0.86	0.86	0.86	623
weighted avg	0.86	0.86	0.86	623

Hình 4.4a. Kết quả các chỉ số đánh giá hiệu suất mô hình đa nhiệm ViT hướng 2 phân loại rắn độc - không độc tại ngưỡng 0.5

Đối với lớp “Độc”, mô hình đạt Precision bằng 0,85 và Recall bằng 0,87, cho thấy hệ thống nhận diện đúng 87% số lượng rắn độc trong tập test, đồng thời duy trì tỷ lệ dự đoán nhầm ở mức thấp. Trong bối cảnh ứng dụng thực tế, Recall của lớp “Độc” là chỉ số đặc biệt quan trọng bởi hậu quả của việc bỏ sót một cá thể rắn độc thường nghiêm trọng hơn nhiều so với việc cảnh báo nhầm một cá thể không độc. Việc duy trì Recall ở mức 0,87 cho thấy mô hình có

khả năng hoạt động như một công cụ sàng lọc an toàn, giúp giảm thiểu nguy cơ nhận diện thiếu các trường hợp tiềm ẩn rủi ro. Ở lớp “Không độc” đạt Precision bằng 0,87 và Recall bằng 0,85. Kết quả này phản ánh sự cân bằng tương đối tốt giữa hai lớp dữ liệu, đồng thời cho thấy mô hình không bị thiên lệch mạnh về bất kỳ phía nào. Điều này đặc biệt đáng chú ý khi tập dữ liệu ban đầu tồn tại sự mất cân bằng giữa các họ rắn và giữa nhóm có độc với không độc. Việc áp dụng WeightedRandomSampler kết hợp với cơ chế gán trọng số trong hàm mất mát đã góp phần giúp mô hình duy trì khả năng nhận dạng ổn định trên cả hai nhóm đối tượng.

Tại ngưỡng tối ưu 0.056, mô hình đạt độ chính xác tổng thể 78%. Mặc dù thấp hơn kết quả khi sử dụng ngưỡng mặc định 0,5, khả năng phát hiện rắn độc được cải thiện đáng kể. Cụ thể, lớp rắn độc đạt Recall bằng 0,97, tương đương với việc mô hình nhận diện đúng 97% số lượng rắn độc trong tập kiểm tra. Chỉ có khoảng 3% trường hợp rắn độc bị bỏ sót, đây là kết quả đặc biệt quan trọng đối với các hệ thống hỗ trợ nhận diện nguy cơ trong thực tế.

[Lớp 1 - Tuned threshold=0.056]				
	precision	recall	f1-score	support
Không độc	0.95	0.59	0.73	311
Độc	0.70	0.97	0.81	312
accuracy			0.78	623
macro avg	0.83	0.78	0.77	623
weighted avg	0.83	0.78	0.77	623
AUC-ROC: 0.9207				

Hình 4.4b. Kết quả các chỉ số đánh giá hiệu suất mô hình đa nhiệm ViT hướng 2 phân loại rắn độc - không độc tại ngưỡng tối ưu 0.056


Sự cải thiện về Recall đạt được thông qua việc hạ thấp ngưỡng quyết định từ 0,5 xuống 0,056. Khi đó, mô hình có xu hướng ưu tiên dự đoán theo hướng “Độc” đối với các trường hợp chưa thực sự chắc chắn. Hệ quả là Recall của lớp rắn độc tăng mạnh từ 0,87 lên 0,97, tuy nhiên Precision giảm xuống còn 0,70. Điều này cho thấy số lượng cảnh báo nhầm tăng lên, tức một số cá thể rắn không độc bị nhận diện nhầm thành rắn độc. Mặc dù vậy, trong bối cảnh hỗ trợ sơ cứu và cảnh báo nguy hiểm, sai sót theo hướng cảnh báo thừa thường được xem là chấp nhận được hơn so với việc bỏ sót một trường hợp rắn độc thực sự. Xu hướng này được thể hiện rõ qua kết quả của lớp “Không độc”. Precision đạt 0,95 cho thấy phần lớn các mẫu được dự đoán là “Không độc” đều chính xác. Tuy nhiên Recall chỉ đạt 0,59, nghĩa là mô hình chỉ nhận diện đúng khoảng 59% số lượng rắn không độc trong tập kiểm tra. Khoảng 41% số mẫu không độc còn lại bị chuyển sang nhóm Có độc do tác động của ngưỡng quyết định thấp. Đây chính là sự đánh đổi có chủ đích nhằm tối đa hóa khả năng phát hiện rắn độc và giảm thiểu nguy cơ bỏ sót các trường hợp nguy hiểm.


Kết quả phân loại họ rắn trên tập kiểm tra gồm 623 mẫu cho thấy mô hình đạt độ chính xác tổng thể 48%, Macro-F1 đạt 0,50 và Macro-Recall đạt 0,70.

[Lớp 2 - Phân họ]				
	precision	recall	f1-score	support
Họ rắn lục Viperidae	0.85	0.68	0.76	130
Rắn biển Hydrophiidae_doc	0.86	0.90	0.88	41
Rắn biển Hydrophiidae_khongdoc	0.14	0.50	0.22	4
Rắn giun Typhlopidae	0.18	0.92	0.30	13
Rắn hổ Elapidae	0.75	0.79	0.77	100
Rắn hổ biển Laticaudinae	0.89	0.73	0.80	11
Rắn nước Colubridae_doc	0.34	0.93	0.50	30
Rắn nước Colubridae_khongdoc	0.93	0.14	0.24	287
Rắn trun Cyndrophiiidae	0.03	0.71	0.06	7
accuracy			0.48	623
macro avg	0.55	0.70	0.50	623
weighted avg	0.82	0.48	0.50	623

Hình 4.4c. Kết quả các chỉ số đánh giá hiệu suất mô hình đa nhiệm ViT hướng 2 phân loại theo họ rắn

Kết quả chi tiết cho thấy mô hình hoạt động tốt trên các lớp có số lượng mẫu tương đối lớn và mang đặc trưng hình thái rõ ràng. Họ rắn biển độc (Hydrophiidae_doc) đạt F1-score cao nhất với giá trị 0,88, đồng thời đạt Recall 0,90. Họ rắn hổ (Elapidae) đạt F1-score 0,77 với Recall 0,79, trong khi họ rắn lục (Viperidae) đạt F1-score 0,76 với Recall 0,68. Đây đều là các nhóm rắn có ý nghĩa y tế quan trọng tại Việt Nam và cũng là những nhóm sở hữu các đặc điểm hình thái tương đối đặc trưng, giúp mô hình học được các biểu diễn ổn định hơn trong quá trình huấn luyện.





Hình 4.4d. Ma trận nhầm lẫn mô hình đa nhiệm ViT hướng 2 phân loại rắn độc - không độc và theo họ rắn

Các dự đoán đúng tập trung chủ yếu trên đường chéo chính, cho thấy mô hình đã học được những đặc trưng hình thái quan trọng phục vụ cho quá trình nhận dạng. Đối với phân loại độc tính, mô hình có xu hướng ưu tiên dự đoán theo hướng “Độc” đối với các trường hợp chưa chắc chắn nhằm giảm thiểu nguy cơ bỏ sót rắn độc. Điều này phù hợp với mục tiêu của dự án. Còn đối với phân loại họ rắn, hiện tượng nhầm lẫn chủ yếu xuất hiện giữa các nhóm có đặc điểm hình thái tương đồng hoặc số lượng mẫu huấn luyện hạn chế. Tuy nhiên, các họ rắn độc quan trọng như Viperidae, Elapidae và Hydrophiidae vẫn được nhận diện tương đối tốt. Kết quả cho thấy mô hình học đa nhiệm đã khai thác hiệu quả mối liên hệ giữa thông tin độc tính và đặc điểm phân loại sinh học, đồng thời vẫn còn dư địa cải thiện đối với các nhóm rắn có mức độ tương đồng cao.

4.5. Kết quả mô hình kết hợp

Kết quả thực nghiệm cho thấy hệ thống đã tìm ra một ngưỡng quyết định tối ưu rất thấp, chỉ ở mức 0.0510 trên tập dữ liệu Validation dưới điều kiện ràng buộc độ chính xác (Precision) đạt tối thiểu 70%. Việc cấu hình một phân ngưỡng thấp phản ánh đúng chiến lược “An toàn là trên hết” vốn là nguyên tắc cốt lõi trong y học và công tác cứu hộ động vật nguy hiểm. Hệ thống thà chấp nhận rủi ro nhận nhầm hơn bỏ sót, chỉ cần mô hình ghi nhận 5.1% nguy cơ một cá thể rắn chứa độc tố, ảnh đầu vào sẽ lập tức được định tuyến sang nhánh xử lý rắn độc nhằm đưa ra cảnh báo mức cao nhất cho người dùng, từ đó giảm thiểu tai nạn đáng tiếc do chủ quan trong thực tế.

TEST SET – Hybrid Pipeline (Lớp 1: H2 threshold=0.051 Lớp 2: H1 chốt cứng)				
[Lớp 1 - Độc/Không độc]				
	precision	recall	f1-score	support
Không độc	0.95	0.58	0.72	311
Độc	0.70	0.97	0.81	312
accuracy			0.77	623
macro avg	0.82	0.77	0.76	623
weighted avg	0.82	0.77	0.76	623
AUC-ROC: 0.9207				


Hình 4.5a. Kết quả các chỉ số đánh giá hiệu suất mô hình kết hợp phân loại rắn độc - không độc tại ngưỡng tối ưu 0.051

Khi đánh giá hiệu năng của bộ lọc Lớp 1 trên tập dữ liệu kiểm thử cân bằng gồm 311 mẫu không độc và 312 mẫu độc, mô hình đã thể hiện năng lực phân tách lớp tốt với chỉ số AUC-ROC đạt tới 0.9207 trước khi áp ngưỡng quyết định. Nhờ chiến lược chủ động hạ thấp ngưỡng, Recall của nhóm rắn độc đã chạm mốc lý tưởng 97%, đồng nghĩa với việc mô hình nhận diện chính xác hầu hết các trường hợp nguy hiểm và chỉ bỏ sót khoảng 3% tổng số mẫu thực tế (tương đương khoảng 9 mẫu). Bên cạnh đó, vùng an toàn của hệ thống cũng đạt độ tin cậy rất cao khi chỉ số Precision của nhãn Không độc đạt 95%, giúp người dùng hoàn toàn an tâm khi mô hình đưa ra kết luận an toàn. Tuy nhiên, sự tối ưu hóa này đòi hỏi một sự đánh đổi kỹ thuật tất yếu khi mô hình vô tình phân loại nhầm 42% mẫu rắn lành tính thành rắn độc, kéo giảm độ thu hồi của nhóm không độc xuống 58% và khiến Precision của nhóm độc chỉ còn 70%. Trong bối cảnh thực tế, sự đánh đổi này hoàn toàn chấp nhận được vì việc cảnh báo né tránh một con rắn lành (do báo động giả) vẫn an toàn hơn nhiều so với việc tiếp cận một con rắn độc bị nhận diện sai.

[Lớp 2 - Phân họ]				
	precision	recall	f1-score	support
Họ rắn lục Viperidae	0.66	0.93	0.77	130
Rắn biển Hydrophiidae_doc	0.78	0.98	0.87	41
Rắn biển Hydrophiidae_khongdoc	1.00	0.50	0.67	4
Rắn giun Typhlopidae	0.60	0.92	0.73	13
Rắn hổ Elapidae	0.64	0.92	0.75	100
Rắn hổ biển Laticaudinae	1.00	0.73	0.84	11
Rắn nước Colubridae_doc	0.53	0.87	0.66	30
Rắn nước Colubridae_khongdoc	0.95	0.52	0.67	287
Rắn trun Cyndrophidae	0.30	0.43	0.35	7
accuracy			0.73	623
macro avg	0.72	0.75	0.70	623
weighted avg	0.79	0.73	0.72	623

Hình 4.5b. Kết quả các chỉ số đánh giá hiệu suất mô hình kết hợp phân loại theo họ rắn

Tổng thể hệ thống phân cấp lại 9 lớp vẫn đạt độ chính xác ấn tượng là 73% đối với một bài toán phân loại sâu phức tạp. Nhờ luồng định tuyến ưu tiên từ Lớp 1, các phân họ rắn độc chính trong tự nhiên đều đạt chỉ số Recall rất cao và đồng đều, cụ thể như rắn biển độc (Hydrophiidae_doc) đạt 98%, họ rắn lục (Viperidae) đạt 93% và họ rắn hổ (Elapidae) đạt 92%. Ở chiều ngược lại, nhóm rắn không độc phải gánh chịu hệ quả từ việc hạ ngưỡng quyết định khi phân họ rắn nước không độc (Colubridae_khongdoc), nhóm có số lượng mẫu lớn nhất với 287 mẫu, chỉ đạt chỉ số Recall là 52% do một lượng lớn dữ liệu bị nhận nhầm và chuyển tiếp sang chuyên gia rắn độc ở Lớp 2. Ngoài ra, hiện tượng mất cân bằng dữ liệu nghiêm trọng ở các nhóm thiểu số như rắn trùn (Cylindrophidae) với chỉ 7 mẫu kiểm thử cũng khiến chỉ số F1-score bị kéo xuống mức thấp 0.35, cho thấy mô hình chưa thể trích xuất tốt đặc trưng phân tách khi thiếu hụt dữ liệu huấn luyện.



Hình 4.5c. Ma trận nhầm lẫn mô hình kết hợp phân loại rắn độc - không độc và phân loại theo họ rắn

4.6. Trực quan hóa mô hình với Attention Rollout

Quá trình tính toán Attention Rollout được thực hiện thông qua hàm `get_attention_rollout()`. Đầu tiên, mô hình được chuyển sang chế độ đánh giá (eval) và thực hiện suy luận với tùy chọn `output_attentions=True` để xuất ra toàn bộ ma trận Self-Attention của các lớp Transformer. Mỗi lớp Transformer tạo ra nhiều Attention Head khác nhau, do đó nghiên cứu sử dụng giá trị trung bình của các head nhằm thu được một ma trận Attention đại diện cho toàn bộ lớp.

```
def get_attention_rollout(model_vit_eager, img_tensor):
    model_vit_eager.eval()
    with torch.no_grad():
        _, _, attentions = model_vit_eager(
            img_tensor.to(DEVICE), output_attentions=True)
```

Để phản ánh luồng thông tin được truyền qua các kết nối tắt, ma trận đơn vị được cộng vào ma trận Attention của từng lớp. Sau đó, ma trận được chuẩn hóa theo từng hàng nhằm đảm bảo tổng xác suất bằng 1. Các ma trận Attention đã hiệu chỉnh tiếp tục được nhân tích lũy từ lớp đầu tiên đến lớp cuối cùng để mô phỏng quá trình lan truyền thông tin xuyên suốt toàn bộ mạng Transformer. Cách tiếp cận này cho phép xác định mức độ ảnh hưởng của từng patch ảnh

đầu vào đối với token phân loại [CLS], là token được sử dụng để đưa ra dự đoán cuối cùng của mô hình.

```
rollout = torch.eye(attention[0].shape[-1])
for attn in attentions:
    attn_avg = attn.squeeze(0).mean(0).cpu()
    attn_aug = attn_avg + torch.eye(attn_avg.shape[0])
    attn_aug = attn_aug / attn_aug.sum(dim=-1, keepdim=True)
    rollout = torch.matmul(attn_aug, rollout)
```

Sau khi hoàn thành quá trình tích lũy Attention, loại bỏ token [CLS] và chỉ giữ lại mức độ chú ý của 196 patch ảnh còn lại. Do Vision Transformer sử dụng kích thước patch 16×16 trên ảnh đầu vào 224×224, các patch được sắp xếp thành lưới 14×14. Bản đồ Attention sau đó được chuẩn hóa về khoảng giá trị từ 0 đến 1 và nội suy trở lại kích thước ảnh gốc nhằm phục vụ trực quan hóa.

```
mask = rollout[0, 1:].numpy()
mask = mask.reshape(14, 14)
mask = (mask - mask.min()) / (mask.max() - mask.min() + 1e-8)
mask = cv2.resize(mask, (224, 224))
return mask
```


Hàm `explain_attention()` nhằm tự động phân tích phân bố Attention trên các vùng khác nhau của cơ thể rắn. Heatmap được chia thành ba khu vực theo chiều dọc gồm vùng đầu, vùng thân và vùng đuôi, đồng thời được phân tích theo chiều ngang để xác định xu hướng tập trung ở phía trái hoặc phải của ảnh. Khi tỷ lệ Attention vượt quá ngưỡng xác định trước, hệ thống sẽ sinh ra mô tả bằng ngôn ngữ tự nhiên.

Quá trình hiển thị kết quả được thực hiện trong hàm `predict_and_visualize()`. Sau khi mô hình hoàn thành dự đoán độc tính và họ rắn, bản đồ Attention Rollout được chuyển đổi thành heatmap màu bằng bảng màu JET và chồng lên ảnh gốc với tỷ lệ pha trộn 50%. Giao diện trực quan gồm ba thành phần: ảnh gốc đầu vào, bản đồ Attention Rollout thể hiện vùng mà mô hình tập trung chú ý, và biểu đồ xác suất dự đoán của các lớp họ rắn. Ngoài ra, còn hiển thị nhãn phân loại cuối cùng, xác suất dự đoán độc tính và phần giải thích tự động được sinh ra từ bản đồ Attention.

```
def predict_and_visualize(image_path, save_path=None):
    img_pil = Image.open(image_path).convert('RGB')
    img_tensor = val_transform(img_pil).unsqueeze(0)
```

Trong hàm `predict_and_visualize()`, ảnh đầu vào được tiền xử lý và đưa vào mô hình đa nhiệm `model_h2_eager` để thực hiện nhiệm vụ phân loại độc tính. Đầu ra logit được chuyển đổi thành xác suất bằng hàm Sigmoid, sau đó áp dụng ngưỡng 0,5 để xác định nhãn cuối cùng là Có độc hoặc Không độc. Sau khi hoàn thành quá trình phân loại, hệ thống sử dụng hàm `get_attention_rollout()` để tạo bản đồ Attention Rollout và hàm `explain_attention()` để sinh mô tả ngắn gọn về những vùng ảnh mà mô hình tập trung chú ý. Nhờ đó, kết quả đầu ra không chỉ cung cấp nhãn dự đoán mà còn hỗ trợ giải thích cơ sở đưa ra quyết định của mô hình.


Ảnh : obs135929994_photo231915707_2.jpg
 Thực tế: Không độc | Rắn nước Colubridae_khongdoc



Dự đoán: ⚠️ Độc (63.8%) | Rắn nước Colubridae_doc

Giải thích: Model chú ý đến vùng thân, phần trái của con rắn.

Ảnh : obs167012480_photo289267106_2.jpeg
 Thực tế: Độc | Họ rắn lục Viperidae



Dự đoán: ⚠️ Độc (98.8%) | Họ rắn lục Viperidae

Giải thích: Model chú ý đến vùng thân của con rắn.

Hình 4.6. Kết quả kiểm tra bằng Attention Rollout cho rắn nước (không độc) và rắn lục (có độc)

Phân tích trực quan thông qua bản đồ nhiệt của kỹ thuật Attention Rollout cho thấy rõ mối tương quan giữa sự phân bố trọng số chú ý không gian và độ chính xác của dự đoán. Trong trường hợp mẫu thử Họ Rắn lục (Viperidae), mô hình thể hiện năng lực trích xuất đặc trưng ưu việt khi hội tụ chính xác sự chú ý vào toàn bộ cấu trúc hình thái thân cá thể đang cuộn tròn, loại bỏ hoàn toàn nhiễu từ hậu cảnh, từ đó đưa ra kết quả phân loại "Độc" với độ tin cậy rất cao (98.8%). Ngược lại, ở trường hợp cá thể Rắn nước (Colubridae) thực tế không độc, bản đồ nhiệt tiết lộ sự tập trung chú ý cục bộ, bị giới hạn ở một vùng thân gấp uốn phía bên trái mà không bao quát toàn diện các đặc điểm nhận dạng quan trọng khác. Sự phân bố trọng số đặc trưng không tối ưu này là cơ sở trực tiếp giải thích cho hiện tượng sai lệch phân lớp (misclassification), khiến mô hình chẩn đoán nhầm thành "Độc" (63.8%) và xếp sai vào nhóm *Colubridae_doc*. Việc đối sánh hai kết quả này giúp minh bạch hóa cơ chế ra quyết định của mạng ViT, chỉ ra rằng tính toàn vẹn của vùng không gian được chú ý là yếu tố then chốt quyết định độ chính xác trong phân loại đa tầng.

CHƯƠNG 5. THẢO LUẬN VÀ HÀM Ý

5.1. Thảo luận kết quả

Kết quả thực nghiệm cho thấy mô hình Vision Transformer có khả năng nhận diện hiệu quả đối với phần lớn các họ rắn trong bộ dữ liệu. Các lớp có số lượng mẫu lớn như *Viperidae*, *Elapidae* và *Colubridae* thường đạt độ chính xác cao hơn do mô hình được tiếp xúc với nhiều biến thể hình ảnh trong quá trình huấn luyện. Số lượng mẫu lớn giúp mô hình học được đầy đủ hơn các đặc trưng về hình thái, màu sắc, hoa văn và cấu trúc vảy của từng nhóm rắn. Ngược lại, hiệu suất của mô hình có xu hướng giảm đối với các lớp có số lượng mẫu hạn chế như *Laticaudinae*, *Cylindrophiiidae* hoặc nhóm *Hydrophiidae_khongdoc*. Nguyên nhân chủ yếu xuất phát từ sự mất cân bằng dữ liệu giữa các lớp, khi số lượng ảnh của lớp lớn nhất và lớp nhỏ nhất chênh lệch tới khoảng 68 lần. Mặc dù nghiên cứu đã áp dụng kỹ thuật Weighted Random Sampler nhằm giảm ảnh hưởng của hiện tượng này, việc thiếu dữ liệu vẫn làm hạn chế khả năng học đặc trưng của mô hình.

Ngoài ra, kết quả phân loại còn chịu ảnh hưởng bởi chất lượng ảnh đầu vào. Một số trường hợp dự đoán sai xuất hiện khi ảnh được chụp ở góc nghiêng, khoảng cách xa hoặc trong điều kiện ánh sáng không thuận lợi. Đặc biệt, nhiều loài rắn tại Việt Nam có màu sắc và hoa văn tương đối giống nhau nhằm phục vụ cơ chế ngụy trang trong tự nhiên, khiến việc phân biệt chỉ dựa trên hình ảnh trở nên khó khăn. Điều này giải thích vì sao một số mẫu thuộc các họ khác nhau vẫn có thể bị nhầm lẫn trong quá trình nhận diện. Kết quả Attention Rollout cho thấy mô hình thường tập trung vào các vùng chứa đầu rắn, cổ, hoa văn đặc trưng trên thân và cấu trúc vảy. Đây là những đặc điểm thường được các chuyên gia sử dụng trong quá trình định danh loài, cho thấy mô hình đã học được các đặc trưng có ý nghĩa sinh học thay vì chỉ dựa vào các yếu tố ngẫu nhiên của ảnh.

5.2. Hàm ý thực tiễn

Tai nạn do rắn cắn vẫn là một vấn đề y tế đáng quan tâm tại Việt Nam, đặc biệt ở các khu vực nông thôn và miền núi. Theo Nguyễn Thiên Tạo (2023), Việt Nam ghi nhận khoảng 30.000 trường hợp bị rắn cắn mỗi năm. Bên cạnh đó, nghiên cứu của Blessmann và cộng sự (2018) tại tỉnh Thừa Thiên Huế cho thấy tỷ lệ rắn cắn ở khu vực miền núi đạt 172 ca trên 100.000 dân mỗi năm, cao hơn đáng kể so với khu vực ven biển (69 ca trên 100.000 dân mỗi năm) và khu vực đô thị (10 ca trên 100.000 dân mỗi năm). Kết quả này cho thấy người dân sinh sống hoặc làm việc tại các khu vực miền núi, rừng và nông thôn là nhóm có nguy cơ tiếp xúc với rắn cao hơn, đồng thời cũng là đối tượng có nhu cầu lớn đối với các công cụ hỗ trợ nhận diện rắn độc trong thực tế.

Từ kết quả thực nghiệm đạt 84% độ chính xác trong bài toán xác định độc tính, hệ thống được đề xuất cho thấy khả năng hỗ trợ nhận diện nhanh rắn độc thông qua ảnh chụp. Mặc dù chưa thể thay thế hoàn toàn chuyên gia hoặc các phương pháp định danh sinh học chuyên sâu, hệ thống có thể đóng vai trò như một công cụ hỗ trợ ra quyết định ban đầu, giúp người dùng có thêm thông tin tham khảo trong các tình huống khẩn cấp. Điểm khác biệt của nghiên cứu không chỉ nằm ở việc phân loại hình ảnh mà còn ở việc kết hợp kết quả nhận diện với cơ sở tri thức về đặc điểm lâm sàng và hướng dẫn sơ cứu. Điều này giúp hệ thống cung cấp thông tin có ý nghĩa thực tiễn hơn so với các mô hình chỉ trả về tên loài hoặc nhãn phân loại. Trong tương lai, hệ thống có thể được triển khai trên nền tảng web hoặc thiết bị di động nhằm hỗ trợ người dân,

kiểm lâm, cán bộ bảo tồn và nhân viên y tế tại các khu vực có nguy cơ cao xảy ra tai nạn rắn cắn.

5.3. Hạn chế của nghiên cứu

Bên cạnh những kết quả đạt được, nghiên cứu vẫn còn một số hạn chế cần được xem xét.

Thứ nhất, bộ dữ liệu vẫn tồn tại sự mất cân bằng đáng kể giữa các lớp. Lớp có số lượng ảnh lớn nhất gồm 1.911 ảnh, trong khi lớp nhỏ nhất chỉ có 28 ảnh. Mặc dù nghiên cứu đã áp dụng Weighted Random Sampler để giảm ảnh hưởng của hiện tượng này, sự chênh lệch dữ liệu vẫn tác động trực tiếp đến khả năng học của mô hình. Điều này thể hiện qua kết quả đánh giá khi một số lớp có rất ít dữ liệu đạt F1-score thấp hơn đáng kể so với các lớp còn lại.

Thứ hai, dữ liệu được thu thập từ nhiều nguồn khác nhau trên Internet nên chất lượng ảnh chưa đồng nhất. Một số ảnh có độ phân giải thấp, bị che khuất một phần cơ thể hoặc không thể hiện rõ các đặc điểm nhận dạng quan trọng như đầu, mắt hoặc hoa văn trên thân. Đây là những yếu tố có thể làm giảm độ chính xác của mô hình trong quá trình dự đoán.

Thứ ba, hệ thống hiện chỉ nhận diện được các nhóm rắn đã xuất hiện trong tập huấn luyện. Khi gặp các loài chưa có trong bộ dữ liệu, loài ngoại lai hoặc các trường hợp có hình thái bất thường, mô hình vẫn buộc phải đưa ra dự đoán thuộc một trong các lớp đã học. Điều này có thể dẫn đến các kết quả nhận diện không chính xác trong thực tế.

Ngoài ra, nghiên cứu mới dừng lại ở mức nhận diện từ ảnh tĩnh. Trong khi đó, việc định danh rắn ngoài thực địa thường cần kết hợp thêm nhiều yếu tố khác như môi trường sống, vị trí địa lý, kích thước cơ thể hoặc đặc điểm hành vi. Đây là những thông tin mà hệ thống hiện tại chưa khai thác được.

5.4. Hướng phát triển tương lai

Từ những hạn chế đã phân tích, một số hướng phát triển có thể được thực hiện trong các nghiên cứu tiếp theo. Trước hết, cần tiếp tục mở rộng bộ dữ liệu, đặc biệt đối với các lớp hiện có số lượng ảnh thấp. Việc bổ sung thêm dữ liệu từ nhiều khu vực địa lý khác nhau sẽ giúp mô hình học được nhiều biến thể hình thái hơn, từ đó nâng cao khả năng tổng quát hóa khi áp dụng vào thực tế.

Bên cạnh việc mở rộng dữ liệu, nghiên cứu có thể phát triển từ mức phân loại họ rắn sang nhận diện ở cấp độ loài. Đây là một hướng đi có ý nghĩa thực tiễn cao bởi cùng một họ có thể bao gồm nhiều loài với mức độ nguy hiểm và biểu hiện lâm sàng khác nhau. Việc nhận diện được chính xác loài sẽ giúp nâng cao giá trị hỗ trợ của hệ thống trong các tình huống thực tế.

Hướng phát triển khác là tích hợp thêm dữ liệu ngoài hình ảnh, chẳng hạn như vị trí địa lý, môi trường sinh sống hoặc thời điểm ghi nhận. Trong thực tế, nhiều loài rắn chỉ phân bố ở một số khu vực nhất định. Việc kết hợp các nguồn dữ liệu này có thể giúp giảm nhầm lẫn giữa các loài có hình thái tương tự nhau.

Cuối cùng, hệ thống có thể được triển khai thành một ứng dụng hoàn chỉnh trên nền tảng web hoặc thiết bị di động. Khi đó, người dùng không chỉ nhận được kết quả nhận diện mà còn có thể truy cập nhanh các thông tin về độc tính, triệu chứng, sơ cứu ban đầu và hướng xử lý phù

hợp. Đây cũng là hướng phát triển giúp đưa kết quả nghiên cứu từ môi trường học thuật đến gần hơn với nhu cầu thực tế của cộng đồng.

TÀI LIỆU THAM KHẢO

- Abnar, S.& Zuidema, W. (2020). Quantifying Attention Flow in Transformers. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 4190-4197. doi:10.18653/v1/2020.acl-main.385
- Ahmed, S. M., Ahmed, M., Nadeem, A., Mahajan, J., Choudhary, A.& Pal, J. (2008). Emergency treatment of a snake bite: Pearls from literature. *Journal of Emergencies, Trauma, and Shock*, 1(2), 97-105. doi:10.4103/0974-2700.43190
- Ahsan, M. M., Mahmud, M. A. P., Saha, P. K., Gupta, K. D., & Siddique, Z. (2022). Effect of data scaling methods on machine learning algorithms and model performance. *Technologies*, 10(3), 52. doi:10.3390/technologies10030052
- Ali, Z. A., Abduljabbar, Z. H., Tahir, H. A., Sallow, A. B., & Almufti, S. M. (2023). Exploring the Power of eXtreme Gradient Boosting Algorithm in Machine Learning: a Review. *Academic Journal of Nawroz University (AJNU)*, 12(2), 320-334. doi:10.25007/ajnu.v12n2a1612
- Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R.& Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82-115. doi:10.1016/j.inffus.2019.12.012
- Blessmann, J., Nguyen, N., Bui, P. A. T., Nguyen, H. M., Chau, P. T. B., Dang, P. B. P., Vo, V. T.& Nguyen, H. L. (2019). Incidence of snakebites in three different geographical regions in ThuaThien Hue province, Central Vietnam. *Toxicon*, 158, S48-S49. doi:10.1016/j.toxicon.2018.10.169
- Bolon, I., Durso, A. M., Botero Mesa, S., Ray, N., Alcoba, G., Chappuis, F., & Ruiz de Castañeda, R. (2020). Identifying the snake: First scoping review on practices of communities and healthcare providers confronted with snakebite across the world. *PLoS ONE*, 15(3), e0229989. doi:https://doi.org/10.1371/journal.pone.0229989
- Bộ Y tế. (2014). Quyết định số 5152/QĐ-BYT về việc ban hành tài liệu "Hướng dẫn chẩn đoán, điều trị rắn lục xanh đuôi đỏ cắn". Được truy lục từ <https://thuvienphapluat.vn/van-ban/The-thao-Y-te/Quyet-dinh-5152-QD-BYT-2014-huong-dan-chan-doan-dieu-tri-ran-luc-xanh-duoi-do-can-261521.aspx>
- Carlos N. Silla Jr., Alex A. Freitas. (2011). A survey of hierarchical classification across different application domains. *Data Mining and Knowledge Discovery*, 22(1-2), 31-72. doi:10.1007/s10618-010-0175-9
- Caruana, R. (1997). Multitask learnin. *Machine Learning*, 28(1), 41-75. doi:10.1023/A:1007379606734
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. doi:10.1145/2939672.2939785

- Chippaux, J.-P. (2017). Incidence and mortality due to snakebite in the Americas. *PLOS Neglected Tropical Diseases*, 11(6), e0005662. doi:10.1371/journal.pntd.0005662
- Durso, A. M., Moorthy, G. K., Mohanty, S. P., Bolon, I., Salathé, M., & Ruiz de Castañeda, R. (2021). Supervised learning computer vision benchmark for snake species identification from photographs: Implications for herpetology and global health. *Frontiers in Artificial Intelligence*, 4, 582110. doi:10.3389/frai.2021.582110
- Gutiérrez, J. M., Calvete, J. J., Habib, A. G., Harrison, R. A., Williams, D. J., & Warrell, D. A. (2017). Snakebite envenoming. *Nature Reviews Disease Primers*, 3, 17063. doi:10.1038/nrdp.2017.63
- Hcini, G., Jdey, I., & Dhahri, H. (2024). Investigating Deep Learning for Early Detection and Decision-Making in Alzheimer's Disease: A Comprehensive Review. *Neural Processing Letters*, 56, 1-38. doi:10.1007/s11063-024-11600-5
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778. doi:10.1109/CVPR.2016.90
- Kasturiratne, A., Wickremasinghe, A. R., de Silva, N., Gunawardena, N. K., Pathmeswaran, A., Premaratna, R., Savioli, L., Lalloo, D. G., & de Silva, H. J. (2008). The global burden of snakebite: A literature analysis and modelling based on regional estimates of envenoming and deaths. *PLOS Medicine*, 5(11), e218. doi:10.1371/journal.pmed.0050218
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems*, 25, 1097-1105. Được truy lục từ https://papers.nips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf
- Le, T. Q., Le, L. T. H., Nguyen, H. H., Ha, H. T., Nguyen, N. T., Nguyen, T. Q., Ziegler, T., Do, T. T., & Nguyen, T. D. (2025). Profile of snakebite cases admitted to the Poison Control Center of Bach Mai Hospital in northern Vietnam from 2008 to 2020. *Transactions of the Royal Society of Tropical Medicine and Hygiene*, 119(4), 432-442. doi:10.1093/trstmh/trae118
- Longbottom, J., Shearer, F. M., Devine, M., Alcoba, G., Chappuis, F., Weiss, D. J., Ray, S. E., Ray, N., Warrell, D. A., Ruiz de Castañeda, R., Williams, D. J., Hay, S. I., & Pigott, D. (2018). Vulnerability to snakebite envenoming: A global mapping of hotspots. *The Lancet*, 392(10148), 673-684. doi:10.1016/S0140-6736(18)31224-8
- Organization, W. H. (2023, September 12). Snakebite envenoming. Được truy lục từ <https://www.who.int/news-room/fact-sheets/detail/snakebite-envenoming>
- Phùng, M. T., Nguyễn, Q. T., & WebAdmin. (2023). Sinh vật rừng Việt Nam. Được truy lục từ <http://vncreatures.net/>

- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 97, 6105-6114. Được truy lục từ <https://proceedings.mlr.press/v97/tan19a.html>
- Tâm, M. (2023). *Lớp học công chúng: “Rắn độc Việt Nam: Đa dạng loài, tầm quan trọng trong nghiên cứu và quản lý tai nạn rắn độc cắn ở Việt Nam*. Được truy lục từ <https://vast.gov.vn/tin-chi-tiet/-/chi-tiet/lop-hoc-cong-chung-ran-%C4%91oc-viet-nam-%C4%91a-dang-loai-tam-quan-trong-trong-nghien-cuu-va-quan-ly-tai-nan-ran-%C4%91oc-can-o-viet-nam--111816-463.html>
- Thang, V. V., Bao, T. Q. Q., Tuyen, H. D., Krumkamp, R., Hai, L. H., Dang, N. H., Nga, N. T. T., Ha, N. M., Duoc, N. T., Khoa, N. T. L., Schmidt-Chanasit, J., & Hamelmann, C. (2020). Incidence of snakebites in Can Tho Municipality, Mekong Delta, South Vietnam-Evaluation of the responsible snake species and treatment of snakebite envenoming. *PLOS Neglected Tropical Diseases*, 14(6), e0008430. doi:10.1371/journal.pntd.0008430
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998-6008. Được truy lục từ https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- World Health Organization. (2016). Guidelines for the Management of Snakebites, 2nd Edition. Được truy lục từ <https://cdn.who.int/media/docs/default-source/searo/india/health-topic-pdf/who-guidance-on-management-of-snakebites.pdf>